École Polytechnique

EA de recherche

(Liquidité et microstructure des marchés)

Simulation d'un Limit Order Book et Élaboration d'une stratégie d'exécution Optimal par reinforcement learning

Auteurs :

Joel TAGNE
Francois MOUSSINGA
Emmanuel ABONDO

Encadrants :
Huyen PHAM
Yadh Hafsi

Abstract

Ce rapport étudie la modélisation du carnet d'ordres et son impact sur les stratégies d'exécution optimale. Deux dynamiques sont considérées : un modèle de Poisson, simple et sans mémoire, et un modèle de Hawkes, capable de reproduire les faits stylisés des marchés électroniques tels que le clustering d'ordres et la variabilité du spread. Dans ce cadre, nous formulons un problème de liquidation d'un inventaire et construisons une stratégie d'apprentissage par renforcement (DQN) reposant sur un système de pénalités reflétant le coût d'exécution, le risque de retard et le risque de non-liquidation. Enfin, nous comparons la performance de l'agent RL à plusieurs stratégies déterministes de référence (TWAP, VWAP, POV), en analysant notamment l'implementation shortfall, les trajectoires d'exécution et les distributions microstructurelles.

Contents

1 Carnet d'ordre avec processus de Poisson **4**
1.1 Modélisation du carnet d'ordres 4
1.2 Dynamique et caractéristiques des évènements 5
1.3 Schéma de simulation et intensités par tick 6
1.4 Loi du minimum de variables exponentielles 8
1.5 Générateur infinitésimal du modèle zéro-intelligence 10
1.6 Ergodicité du carnet d'ordres 11
1.7 Analyse des features du carnet d'ordres simulé sous un modèle de Poisson . 13
1.7.1 Mid-price : définition et interprétation 14
1.7.2 Spread : définition et interprétation 14
1.7.3 Total depth: définition et interprétation 15
1.7.4 Imbalance : définition et interprétation 16
1.7.5 Cross-correlation du mid-price : mise en évidence de l'absence de clustering 16
1.7.6 Convergence de la volatilité asymptotique : comparaison avec la théorie 16
1.7.7 Tests d'ajustement Poisson : Q-Q plot et indépendance 17

2 Carnet d'ordre avec processus de Hawkes **18**
2.1 Noyaux exponentiels et condition de stabilité 20
2.2 Algorithme de thinning d'Ogata pour la simulation exacte 20
2.3 Générateur infinitésimal du carnet d'ordres avec intensités de Hawkes . . . 22
2.4 Analyse des features du carnet d'ordres sous modèles de Hawkes 24
2.4.1 Mid-price : réactions en régime auto-existant 26
2.4.2 Spread et micro-liquidité 26
2.4.3 Profondeur et déséquilibre de volume 27
2.4.4 Intensités Hawkes et phénomène de clustering 27
2.4.5 Cross-correlation du mid-price et mémoire du marché 28
2.4.6 Volatilité asymptotique du prix et théorème limite 29

3 Problème d'exécution optimale **29**
3.1 État de l'art 30
3.2 Processus de décision markovien (MDP) 31
3.2.1 Fonction valeur en horizon fini 32
3.2.2 Équation de programmation dynamique 32
3.3 Apprentissage par renforcement 33
3.4 Stratégie d'exécution par apprentissage par renforcement 34
3.5 Stratégies baselines et comparaison avec le RL 36
3.6 Configuration d'apprentissage 37
3.7 Analyse des performances de la stratégie RL 38

Introduction

Au cours des vingt dernières années, l'essor spectaculaire du trading électronique et l'influence croissante des investisseurs institutionnels ont profondément transformé la microstructure des marchés financiers. Les transactions sont désormais fragmentées en une multitude d'ordres de petite taille exécutés continuellement dans un environnement organisé autour du carnet d'ordres électronique (Limit Order Book, LOB). Dans ce contexte, la mesure de la liquidité, l'évaluation de l'impact de marché et la conception de stratégies d'exécution efficaces sont devenues des enjeux centraux pour les acteurs du marché comme pour la recherche académique.

La littérature montre que les *coûts d'exécution* — incluant les commissions, le bid–ask spread, les coûts d'opportunité et surtout l'impact de marché — peuvent réduire de manière significative la performance d'une stratégie d'investissement. Comme le soulignent Bertsimas et Lo [1], la différence entre le prix théorique d'un actif et le prix réellement obtenu lors d'une exécution peut générer un *implementation shortfall* important, susceptible d'annuler une part non négligeable du rendement anticipé. Dans un marché fragmenté où les flux d'ordres présentent une forte hétérogénéité temporelle, la capacité à anticiper et contrôler ces coûts constitue un avantage décisif.

Pour analyser ces phénomènes, il est indispensable de disposer d'outils de simulation capables de reproduire la dynamique fine du carnet d'ordres. Les modèles dits *zéro-intelligence*, fondés sur des processus de Poisson indépendants, fournissent un premier cadre simple permettant de capturer les mécanismes élémentaires d'arrivée d'ordres, d'annulation et d'exécution. Toutefois, de nombreuses études empiriques (voir notamment Bouchaud et al.; Cont, Stoikov et Talreja) mettent en évidence des propriétés absentes des modèles de Poisson : autocorrélation des arrivées d'ordres, excitation mutuelle entre ordres limites et ordres de marché, et phénomènes de *clustering*. Les processus de Hawkes, introduits par Hawkes (1971), se sont révélés particulièrement adaptés pour modéliser ces effets d'auto-excitation.

Dans ce travail, nous développons et comparons deux cadres de simulation du carnet d'ordres : (i) un modèle de Poisson indépendant servant de référence, et (ii) un modèle de Hawkes multivarié (et bi-interaction), capable de reproduire les structures de dépendance observées en haute fréquence. Ces simulations permettent d'étudier l'évolution du mid-price, du spread, de la profondeur et des déséquilibres de carnet, qui constituent des indicateurs essentiels pour comprendre la formation des prix et la disponibilité de la liquidité.

Sur cette base, nous introduisons le *problème d'exécution optimale*, dont l'objectif est de déterminer comment liquider une position initiale tout en minimisant les coûts générés par l'impact de marché. Ce problème, intrinsèquement dynamique, dépend de la manière dont le prix réagit aux flux d'ordres ainsi qu'aux actions du trader lui-même. Les modèles classiques d'Almgren–Chriss et de Bertsimas–Lo fournissent un cadre analytique pour décrire ce compromis entre coût, liquidité et risque. L'environnement simulé que nous construisons permet d'aller plus loin en intégrant des dynamiques réalistes issues de la microstructure, et sert ainsi de base à l'élaboration de stratégies d'exécution, notamment via l'apprentissage par renforcement.

1 Carnet d'ordre avec processus de Poisson

1.1 Modélisation du carnet d'ordres

On considère une grille de prix discrète

$$\mathcal{P} = \{1, 2, \ldots, n\},$$

où chaque entier i représente directement un niveau de prix.

L'état du carnet au temps t est décrit par un vecteur

$$X(t) = \big(X_1(t), \ldots, X_n(t)\big),$$

où chaque composante $X_i(t)$ code la profondeur au niveau de prix i :

- si $X_i(t) < 0$, il y a $-X_i(t)$ ordres d'achat limit (bid) au prix i ;
- si $X_i(t) > 0$, il y a $X_i(t)$ ordres de vente limit (ask) au prix i ;
- si $X_i(t) = 0$, aucun ordre n'est présent au niveau i.

Un seul processus $X(t)$ suffit donc à représenter les deux côtés du carnet ; le signe de $X_i(t)$ distingue le côté bid du côté ask. Le modèle est structurellement symétrique : échanger bid et ask revient à remplacer $X(t)$ par $-X(t)$.

À partir de $X(t)$, on définit les meilleurs prix bid et ask par

$$A_t = \inf\{\, i \in \{1, \ldots, n\} : X_i(t) > 0 \,\}, \qquad B_t = \sup\{\, i \in \{1, \ldots, n\} : X_i(t) < 0 \,\},$$

avec les conventions

$$A_t = n{+}1 \quad \text{si aucun niveau ask n'est présent,} \qquad B_t = 0 \quad \text{si aucun niveau bid n'est présent.}$$

Lorsque les deux côtés sont non vides, on a $0 < B_t < A_t \leq n + 1$. On en déduit les quantités classiques :

$$P_t^b = B_t, \qquad P_t^a = A_t,$$
$$M_t = \frac{P_t^b + P_t^a}{2} = \frac{A_t + B_t}{2},$$

et le spread (en ticks, qui coïncident ici avec les unités de prix) :

$$\text{spread}_t = P_t^a - P_t^b = A_t - B_t.$$

La notion de *distance en ticks* intervient dans la paramétrisation des intensités. Pour un niveau de prix i et un instant t, on définit par exemple :

$$d_i^{\text{bid}}(t) = \begin{cases} B_t - i, & \text{si } i \leq B_t, \\ +\infty, & \text{sinon,} \end{cases} \qquad d_i^{\text{ask}}(t) = \begin{cases} i - A_t, & \text{si } i \geq A_t, \\ +\infty, & \text{sinon.} \end{cases}$$

Dans le modèle symétrique, les intensités dépendent uniquement de ces distances entières (nombre de ticks par rapport au meilleur prix), et non du niveau absolu i.

1.2 Dynamique et caractéristiques des évènements

La dynamique du carnet est gouvernée par trois types d'évènements : arrivées d'ordres limit, annulations d'ordres existants et ordres au marché. Chaque évènement modifie le vecteur $X(t)$ et, par conséquent, les meilleurs prix P_t^b et P_t^a, le mid-price M_t et le spread.

Arrivées d'ordres limit

Un ordre limit peut arriver à un niveau de prix $i \in \{1, \ldots, n\}$:

- arrivée d'un *limit buy* au prix i :

$$X_i(t) \leftarrow X_i(t) - 1;$$

- arrivée d'un *limit sell* au prix i :

$$X_i(t) \leftarrow X_i(t) + 1.$$

Dans le cadre symétrique, les intensités d'arrivée dépendent uniquement de la distance en ticks au meilleur prix opposé. Par exemple, pour un limit buy placé à k ticks en dessous du meilleur ask, l'intensité est $\lambda(k)$, et de même pour un limit sell placé à k ticks au-dessus du meilleur bid. Pour une distance $k \geq 1$, limit buy et limit sell partagent la même intensité $\lambda(k)$.

Annulations d'ordres limit

Un ordre existant au prix i peut être annulé :

- si $X_i(t) < 0$ (bid), on annule un ordre d'achat :

$$X_i(t) \leftarrow X_i(t) + 1;$$

- si $X_i(t) > 0$ (ask), on annule un ordre de vente :

$$X_i(t) \leftarrow X_i(t) - 1.$$

Le taux d'annulation au niveau i est proportionnel au nombre d'ordres présents, avec un coefficient dépendant de la distance en ticks. Si l'on note $d_i(t)$ la distance adéquate (au meilleur bid ou au meilleur ask, selon le côté), le taux d'annulation s'écrit typiquement

$$\lambda_i^C(t) = \theta\big(d_i(t)\big)\, |X_i(t)|,$$

où $\theta(\cdot)$ est une fonction de taux commune aux deux côtés.

Ordres au marché

Un ordre au marché consomme immédiatement la meilleure contrepartie :

- un *market buy* frappe le meilleur ask A_t :

$$X_{A_t}(t) \leftarrow X_{A_t}(t) - 1.$$

  Si $X_{A_t}(t)$ devient nul, le niveau A_t ne contient plus d'ordres ask ; on redéfinit alors le meilleur ask comme le plus petit $i > A_t$ tel que $X_i(t) > 0$, ou bien on pose $A_t = n + 1$ s'il n'y a plus d'ask. Le meilleur ask P_t^a, le mid-price M_t et le spread sont mis à jour en conséquence ;

- un *market sell* frappe le meilleur bid B_t :

$$X_{B_t}(t) \leftarrow X_{B_t}(t) + 1.$$

  Si $X_{B_t}(t)$ devient nul, on redéfinit le meilleur bid comme le plus grand $i < B_t$ tel que $X_i(t) < 0$, ou $B_t = 0$ s'il n'y a plus de bid. Là encore, P_t^b, M_t et le spread sont mis à jour.

Dans le modèle symétrique, market buy et market sell arrivent avec la même intensité constante μ.

1.3 Schéma de simulation et intensités par tick

À un instant donné t, l'état du carnet est donné par le vecteur

$$X(t) = (X_1(t), \ldots, X_n(t)),$$

défini sur la grille de prix $\{1, \ldots, n\}$. Pour simuler la dynamique, on associe à *chaque tick* de la grille et à *chaque type d'évènement possible* une intensité propre, puis on utilise la somme de toutes ces intensités pour déterminer le prochain saut.

On introduit l'ensemble des évènements élémentaires

$$\mathcal{E} = \{(\mathrm{LB}, i),\ (\mathrm{LS}, i),\ (\mathrm{CB}, i),\ (\mathrm{CA}, i) : i = 1, \ldots, n\} \ \cup\ \{\mathrm{MB},\ \mathrm{MS}\},$$

où :

- (LB, i) : arrivée d'un limit buy au prix i,
- (LS, i) : arrivée d'un limit sell au prix i,
- (CB, i) : annulation d'un ordre bid au prix i,
- (CA, i) : annulation d'un ordre ask au prix i,
- MB : market buy (frappe le meilleur ask A_t),

- MS : market sell (frappe le meilleur bid B_t).

Pour chaque évènement $e \in \mathcal{E}$, on définit une intensité $\lambda_e(X(t)) \geq 0$ qui dépend de l'état courant $X(t)$ et, en particulier, de la distance en ticks au meilleur prix :

- pour les arrivées de limits au prix i,

$$\lambda_{(\mathrm{LB},i)}(X(t)) = \lambda_{\mathrm{buy}}\big(d_i^{\mathrm{ask}}(t)\big), \qquad \lambda_{(\mathrm{LS},i)}(X(t)) = \lambda_{\mathrm{sell}}\big(d_i^{\mathrm{bid}}(t)\big),$$

  où $d_i^{\mathrm{ask}}(t)$ et $d_i^{\mathrm{bid}}(t)$ sont les distances en ticks au meilleur ask / bid ;

- pour les annulations au prix i,

$$\lambda_{(\mathrm{CB},i)}(X(t)) = \theta_{\mathrm{bid}}\big(d_i^{\mathrm{bid}}(t)\big)\,(-X_i(t))_+, \qquad \lambda_{(\mathrm{CA},i)}(X(t)) = \theta_{\mathrm{ask}}\big(d_i^{\mathrm{ask}}(t)\big)\,(X_i(t))_+,$$

  avec $(x)_+ = \max(x, 0)$;

- pour les ordres au marché,

$$\lambda_{\mathrm{MB}}(X(t)) = \mu_{\mathrm{buy}}, \qquad \lambda_{\mathrm{MS}}(X(t)) = \mu_{\mathrm{sell}},$$

  typiquement constants.

Les intensités sont donc définies *par tick* de la grille (pour les évènements locaux) ou au meilleur prix (pour les market orders). On définit ensuite la somme totale

$$\Lambda(X(t)) = \sum_{e \in \mathcal{E}} \lambda_e(X(t)).$$

La propriété du minimum de lois exponentielles permet alors de simuler la superposition de tous ces processus de Poisson :

- le temps jusqu'au prochain évènement

$$\Delta T \sim \mathrm{Exp}\big(\Lambda(X(t))\big);$$

- la probabilité que le prochain évènement soit précisément $e \in \mathcal{E}$ vaut

$$\mathbb{P}\big(\text{prochain évènement} = e \,\big|\, X(t)\big) = \frac{\lambda_e(X(t))}{\Lambda(X(t))}.$$

En pratique, le schéma de simulation est le suivant :

1. À partir de l'état courant $X(t)$, on parcourt la grille $i = 1, \ldots, n$ et l'on calcule, pour chaque tick et chaque type local, les intensités

$$\lambda_{(\mathrm{LB},i)},\ \lambda_{(\mathrm{LS},i)},\ \lambda_{(\mathrm{CB},i)},\ \lambda_{(\mathrm{CA},i)},$$

   puis on ajoute les intensités globales $\lambda_{\mathrm{MB}}, \lambda_{\mathrm{MS}}$.

2. On calcule la somme
$$\Lambda(X(t)) = \sum_{e\in\mathcal{E}} \lambda_e(X(t)).$$

3. On tire le temps du prochain évènement
$$\Delta T \sim \mathrm{Exp}\big(\Lambda(X(t))\big),$$
et l'on met à jour le temps : $t \leftarrow t + \Delta T$.

4. On choisit un évènement $e \in \mathcal{E}$ au hasard, avec probabilité
$$\mathbb{P}(E = e \mid X(t)) = \frac{\lambda_e(X(t))}{\Lambda(X(t))}.$$
Concrètement, cela revient à construire un vecteur des intensités $\big(\lambda_e(X(t))\big)_{e\in\mathcal{E}}$ et à tirer un indice aléatoire proportionnel à ces intensités : cet indice encode à la fois le type d'évènement et, le cas échéant, le tick i.

5. On met à jour $X(t)$ en appliquant la règle correspondant à e :
   - $e = (\mathrm{LB}, i)$: $X_i \leftarrow X_i - 1$,
   - $e = (\mathrm{LS}, i)$: $X_i \leftarrow X_i + 1$,
   - $e = (\mathrm{CB}, i)$: $X_i \leftarrow X_i + 1$,
   - $e = (\mathrm{CA}, i)$: $X_i \leftarrow X_i - 1$,
   - $e = \mathrm{MB}$: on modifie X_{A_t} et on recalcule le meilleur ask,
   - $e = \mathrm{MS}$: on modifie X_{B_t} et on recalcule le meilleur bid.

6. À partir du nouvel état $X(t)$, on recalcule
$$B_t, \quad A_t, \quad P_t^b, \quad P_t^a, \quad M_t, \quad \mathrm{spread}_t,$$
puis on revient à l'étape 1 jusqu'à l'horizon $T_{\max}$.

On voit ainsi clairement que les intensités sont définies pour chaque tick de la grille et pour chaque type d'évènement, et que la somme de ces intensités sert à gérer le temps global du prochain saut, tandis que la répartition relative des intensités décide du type et du niveau de prix de cet évènement.

1.4 Loi du minimum de variables exponentielles

On rappelle ici la propriété utilisée pour la simulation des temps de saut.

Proposition 1.1. *Soient $E_1, \dots, E_n$ des variables aléatoires indépendantes telles que*
$$E_i \sim \mathrm{Exp}(\lambda_i), \qquad \lambda_i > 0.$$
Alors :

1. *Le minimum*

$$T := \min_{1 \le i \le n} E_i$$

suit une loi exponentielle de paramètre

$$\Lambda := \sum_{i=1}^{n} \lambda_i.$$

Autrement dit, $T \sim \mathrm{Exp}(\Lambda)$.

2. *Pour chaque* $i \in \{1, \dots, n\}$, *la probabilité que le minimum soit réalisé par* E_i *vaut*

$$\mathbb{P}\big(T = E_i\big) = \frac{\lambda_i}{\Lambda}.$$

Démonstration. Pour tout $t \ge 0$, on commence par calculer la fonction de survie de T :

$$\mathbb{P}(T > t) = \mathbb{P}\big(E_1 > t, \dots, E_n > t\big).$$

Par indépendance des E_i, on a

$$\mathbb{P}(T > t) = \prod_{i=1}^{n} \mathbb{P}(E_i > t).$$

Or, si $E_i \sim \mathrm{Exp}(\lambda_i)$, alors

$$\mathbb{P}(E_i > t) = e^{-\lambda_i t}, \qquad t \ge 0,$$

d'où

$$\mathbb{P}(T > t) = \prod_{i=1}^{n} e^{-\lambda_i t} = \exp\left(-t \sum_{i=1}^{n} \lambda_i\right) = e^{-\Lambda t}.$$

On reconnaît la fonction de survie d'une loi exponentielle de paramètre Λ, ce qui montre que

$$T \sim \mathrm{Exp}(\Lambda).$$

Pour la probabilité que le minimum soit réalisé par E_i, on peut écrire, pour $t \ge 0$, On note $E_1, \dots, E_n$ des variables aléatoires indépendantes telles que

$$E_k \sim \mathrm{Exp}(\lambda_k), \qquad \lambda_k > 0,$$

et

$$T = \min(E_1, \dots, E_n), \qquad \Lambda = \sum_{k=1}^{n} \lambda_k.$$

On veut calculer la probabilité que le minimum soit réalisé par E_i, c'est-à-dire

$$\mathbb{P}(T = E_i) = \mathbb{P}(E_i < E_j,\ \forall j \ne i).$$

En conditionnant par rapport à E_i, on obtient

$$\mathbb{P}(T = E_i) = \int_0^\infty \mathbb{P}\big(E_i \in \mathrm{d}t,\ E_i < E_j\ \forall j \neq i\big).$$

Par définition de la densité de E_i et par indépendance,

$$\mathbb{P}\big(E_i \in \mathrm{d}t,\ E_i < E_j\ \forall j \neq i\big) = f_{E_i}(t)\,\mathbb{P}\big(E_j > t,\ \forall j \neq i\big)\,\mathrm{d}t,$$

d'où

$$\mathbb{P}(T = E_i) = \int_0^\infty f_{E_i}(t)\,\mathbb{P}\big(E_j > t,\ \forall j \neq i\big)\,\mathrm{d}t.$$

Comme $E_i \sim \mathrm{Exp}(\lambda_i)$,

$$f_{E_i}(t) = \lambda_i e^{-\lambda_i t}, \qquad t \geq 0,$$

et, pour $j \neq i$,

$$\mathbb{P}(E_j > t) = e^{-\lambda_j t}.$$

Par indépendance des E_j,

$$\mathbb{P}\big(E_j > t,\ \forall j \neq i\big) = \prod_{j \neq i} e^{-\lambda_j t} = e^{-t\sum_{j\neq i}\lambda_j} = e^{-(\Lambda - \lambda_i)t}.$$

On en déduit

$$\mathbb{P}(T = E_i) = \int_0^\infty \lambda_i e^{-\lambda_i t}\, e^{-(\Lambda-\lambda_i)t}\,\mathrm{d}t = \int_0^\infty \lambda_i e^{-\Lambda t}\,\mathrm{d}t.$$

Enfin,

$$\int_0^\infty \lambda_i e^{-\Lambda t}\,\mathrm{d}t = \lambda_i \int_0^\infty e^{-\Lambda t}\,\mathrm{d}t = \lambda_i \left[-\frac{1}{\Lambda} e^{-\Lambda t}\right]_0^\infty = \frac{\lambda_i}{\Lambda},$$

ce qui montre que

$$\mathbb{P}(T = E_i) = \frac{\lambda_i}{\Lambda}.$$

1.5 Générateur infinitésimal du modèle zéro-intelligence

Le processus $(X(t))_{t\geq 0}$ décrivant l'évolution du carnet d'ordres est un processus de Markov pur-saut. Chaque transition correspond à l'un des évènements élémentaires décrits précédemment: arrivée d'un *limit buy* ou *limit sell*, annulation d'un ordre existant, ou exécution d'un *market order* frappant le meilleur prix.

Pour chaque évènement $e \in \mathcal{E}$, on note $X^{(e)}$ l'état obtenu en appliquant e à l'état courant X, et $\lambda_e(X)$ son intensité. Le *générateur infinitésimal* du processus est défini pour toute fonction test $f : \mathbb{Z}^n \to \mathbb{R}$ par

$$(\mathcal{L}f)(X) = \sum_{e\in\mathcal{E}} \lambda_e(X)\,\big[\,f(X^{(e)}) - f(X)\,\big].$$

Une *fonction test* f est une observable quelconque du carnet, par exemple : le spread, le mid-price, la profondeur totale $\sum_i |X_i|$, une fonction de Lyapunov utilisée pour analyser la stabilité du système.

Ainsi, $(\mathcal{L}f)(X)$ représente la dérivée instantanée en moyenne de l'observable f lorsque le carnet se trouve à l'état X.

En développant selon les différents types d'évènements, on obtient l'expression explicite :

$$\begin{aligned}(\mathcal{L}f)(X) = &\sum_{i=1}^{n} \lambda_{(\mathrm{LB},i)}(X)\left[f(X^{(\mathrm{LB},i)}) - f(X)\right] + \sum_{i=1}^{n} \lambda_{(\mathrm{LS},i)}(X)\left[f(X^{(\mathrm{LS},i)}) - f(X)\right] \\ &+ \sum_{i=1}^{n} \lambda_{(\mathrm{CB},i)}(X)\left[f(X^{(\mathrm{CB},i)}) - f(X)\right] + \sum_{i=1}^{n} \lambda_{(\mathrm{CA},i)}(X)\left[f(X^{(\mathrm{CA},i)}) - f(X)\right] \\ &+ \lambda_{\mathrm{MB}}(X)\left[f(X^{(\mathrm{MB})}) - f(X)\right] + \lambda_{\mathrm{MS}}(X)\left[f(X^{(\mathrm{MS})}) - f(X)\right].\end{aligned}$$

1.6 Ergodicité du carnet d'ordres

Pour établir la stabilité du modèle, on introduit la fonction de Lyapunov

$$V(X) := \sum_{i=1}^{n} |X_i| + c,$$

où $c > 0$ est une constante. Cette fonction mesure la profondeur totale du carnet.

On suppose que :

- les taux d'annulation sont uniformément positifs :

$$\inf_i \theta_i > 0;$$

- les intensités d'arrivée de limits et les intensités des market orders sont bornées ;
- la grille de prix est finie (*finite moving frame*).

Sous ces conditions, on peut établir une inégalité de drift classique.

Proposition 1.2 (Inégalité de drift)**.** *Il existe des constantes $\beta > 0$, $\gamma > 0$ et un compact $K \subset \mathbb{Z}^n$ tels que*

$$(\mathcal{L}V)(X) \;\le\; -\beta\, V(X) + \gamma, \qquad X \notin K. \tag{1}$$

Proof. L'effet des arrivées d'ordres limit est d'augmenter $V(X)$ de 1, tandis que les annulations, dont le taux est proportionnel au nombre d'ordres présents, diminuent systématiquement $V(X)$. Plus précisément, lorsque $|X_i|$ est grand, les termes provenant des annulations dominent ceux provenant des arrivées, car

$$\lambda_{(\mathrm{CB},i)}(X) \sim \theta_i\, |X_i|, \qquad \lambda_{(\mathrm{CA},i)}(X) \sim \theta_i\, |X_i|.$$

Les événements au marché contribuent également à réduire $V(X)$ dès qu'ils rencontrent une profondeur suffisante.

On obtient alors une expression du type

$$(\mathcal{L}V)(X) \leq -(\theta_{\min} - \varepsilon)\, V(X) + C,$$

pour une constante $C > 0$ et un $\varepsilon > 0$ arbitrairement petit dès que X sort d'un compact (profondeur minimale requise pour que les annulations dominent). On pose alors $\beta := \theta_{\min} - \varepsilon > 0$ et $\gamma := C$, ce qui donne l'inégalité (1). □

Théorème 1.3 (Ergodicité)**.** *Le processus de Markov $(X(t))_{t\geq 0}$ admet une unique distribution stationnaire π. De plus, il est géométriquement ergodique : il existe des constantes $C > 0$ et $0 < \rho < 1$ telles que, pour tout état initial X,*

$$\left\|\mathbb{P}_X\big(X(t) \in \cdot\big) - \pi(\cdot)\right\|_{\mathrm{TV}} \;\leq\; C\,\rho^t.$$

Proof. L'inégalité de drift (1) montre que V est une fonction de Lyapunov coercitive. Comme l'espace d'états est dénombrable et que les ensembles compacts sont *petite sets* au sens de Meyn–Tweedie, le critère de Foster–Lyapunov garantit que le processus est *V-uniformément ergodique*. On obtient alors l'existence d'une unique mesure stationnaire et la convergence exponentielle en variation totale. □

Corollaire 1.4 (Stationnarité du spread)**.** *Le spread $S(t) = P_t^a - P_t^b$ admet une distribution stationnaire. En particulier, la quantité $i_S \Delta P$ décrivant son nombre de ticks possède une loi limite bien définie.*

Théorème 1.5 (Convergence diffusif du prix dans le modèle de Poisson)**.** *Soit $(X(t))_{t\geq 0}$ le processus de carnet d'ordres du modèle de Poisson précédent, et soit P_t le prix défini par*

$$P_t \;=\; \sum_{e\in\mathcal{E}} \int_0^t F_e(X(s))\; dN_e(s),$$

où N_e est le processus de Poisson associé à l'événement e et $F_e(X)$ le déplacement de prix provoqué par cet événement.

On définit également le compensateur prévisible :

$$Q_t \;=\; \sum_{e\in\mathcal{E}} \int_0^t \lambda_e(X(s))\; F_e(X(s))\; ds,$$

et le prix recentré et renormalisé :

$$\widehat{P}^{(n)}(t) \;=\; \frac{P(nt) - Q(nt)}{\sqrt{n}}.$$

Alors, sous la mesure stationnaire π du carnet $X(t)$, le processus $\widehat{P}^{(n)}$ converge en loi, lorsque $n \to \infty$, vers un mouvement brownien de variance asymptotique

$$\widehat{\sigma}^2 \;=\; \sum_{e\in\mathcal{E}} \int F_e(x)^2\, \lambda_e(x)\, \pi(dx).$$

Proof. Sous la distribution stationnaire π, le terme compensé

$$M_t \;=\; P_t - Q_t$$

est une martingale purement discontinue dont les sauts sont bornés : $|F_e(X)| \leq \frac{1}{2}$ pour tout état X.

Son crochet prévisible s'écrit

$$\langle M \rangle_t = \sum_{e \in \mathcal{E}} \int_0^t \lambda_e(X(s))\; F_e(X(s))^2 \; ds.$$

Par le théorème ergodique appliqué au processus $X(t)$ (théorème 1.3), on a presque sûrement :

$$\frac{1}{t}\,\langle M \rangle_t \;\longrightarrow\; \sum_{e \in \mathcal{E}} \int \lambda_e(x)\, F_e(x)^2\, \pi(dx).$$

Comme les sauts sont uniformément bornés, les conditions du théorème central limite pour les martingales (Brown & Heyde) sont vérifiées. On obtient alors la convergence en loi :

$$\widehat{P}^{(n)} \;\Longrightarrow\; \widehat{\sigma}\, W,$$

où W est un mouvement brownien standard. □

1.7 Analyse des features du carnet d'ordres simulé sous un modèle de Poisson

Nous simulons la dynamique du carnet d'ordres sous un modèle de Poisson indépendant. Les paramètres utilisés sont directement inspirés des estimations empiriques de Cont, Stoikov et Talreja (2010) sur les données de Sky Perfect Communications [16]. Nous regroupons l'essentiel des données de simulations dans le tableau ci dessous :

Paramètres du modèle Poisson	**Valeur**
Nombre de niveaux L	5
Arrivées de LO λ_i	[1.85, 1.51, 1.09, 0.88, 0.77]
Taux d'annulation θ_i	[0.71, 0.81, 0.68, 0.56, 0.47]
Taux des ordres de marché μ	0.94
Taille du tick	1.0
Profondeur initiale (tirage aléatoire)	$\sim$ Unif$\{1, 2, 3\}$
Paramètre de réapprovisionnement	Poisson(1.0)
Prix initial (mid-price)	100
Horizon de simulation	60
Méthode de simulation	Gillespie (événements Poisson)

Table 1: Hyperparamètres utilisés pour la simulation du carnet d'ordres Poisson.

Nous présentons ci-dessous les principales grandeurs caractéristiques du carnet d'ordres.

1.7.1 Mid-price : définition et interprétation

Le *mid-price* est défini comme

$$P_{\text{mid}}(t) = \frac{P_{\text{best bid}}(t) + P_{\text{best ask}}(t)}{2}.$$

Il constitue une mesure centrale du niveau de prix autour duquel s'organisent les échanges. Dans notre simulation Poisson, la trajectoire du mid-price présente une dérive lente et irrégulière. Cette dynamique est principalement due :

- aux **rolls mécaniques du carnet**, qui déplacent le mid-price d'un demi-tick à chaque vidage du meilleur niveau ;
- à l'effet cumulatif d'**arrivées symétriques mais aléatoires** d'ordres limites, d'annulations et de market orders.

L'évolution reste très *diffusive*, sans tendance persistante : un comportement typique des modèles de Poisson indépendants.

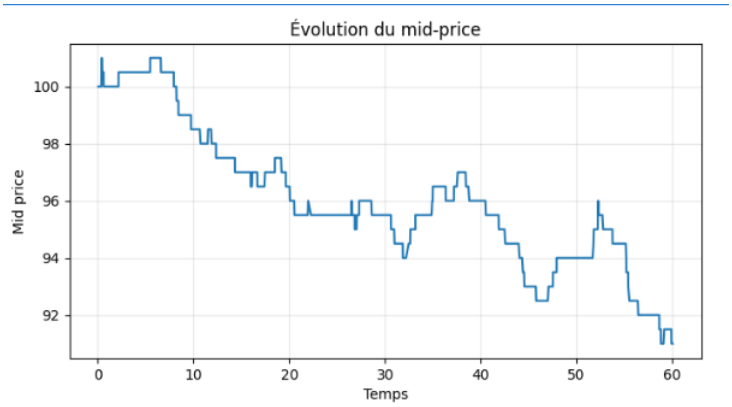

Figure 1: Évolution du mid-price simulé (modèle Poisson)

1.7.2 Spread : définition et interprétation

Le spread est défini par

$$\text{Spread}(t) = P_{\text{best ask}}(t) - P_{\text{best bid}}(t).$$

Il représente le coût immédiat d'exécution au marché. Dans la simulation, le spread reste presque toujours égal à deux ticks, avec de rares élargissements ponctuels à trois ticks. Ce comportement illustre un marché **sans auto-excitation** : aucune dynamique ne maintient durablement un spread large, et le système revient rapidement vers son régime stationnaire.

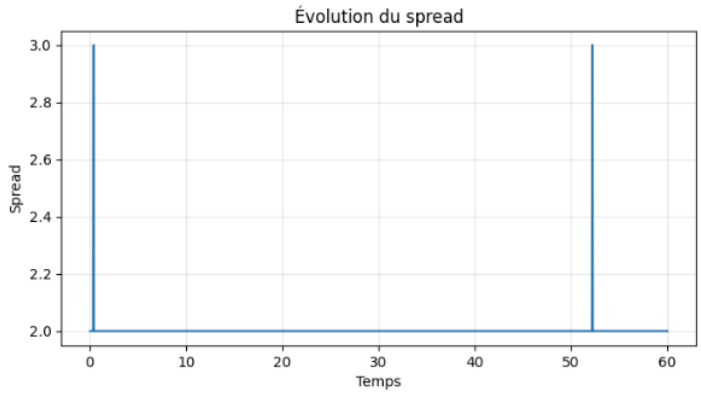

Figure 2: Évolution du spread simulé (modèle Poisson)

1.7.3 Total depth: définition et interprétation

La profondeur cumulée au niveau k est définie par

$$TD_h^k(t) = \sum_{j=1}^{k} Q_h^j(t), \qquad h \in \{\text{bid}, \text{ask}\}.$$

Elle mesure la quantité de liquidité disponible derrière le meilleur prix. Les courbes simulées montrent une profondeur très variable, caractéristique des arrivées et annulations Poissoniennes :

- les pics correspondent à l'arrivée de plusieurs ordres limites consécutifs.
- les chutes proviennent des annulations ou market orders consommant le niveau.

Aucune persistance n'est visible : le modèle ne génère pas l'accumulation durable de liquidité observée sur données réelles.

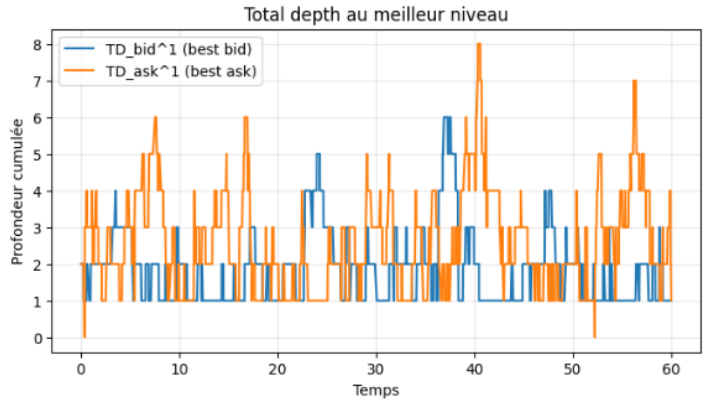

Figure 3: Profondeur cumulée au meilleur niveau bid et ask

1.7.4 Imbalance : définition et interprétation

L'imbalance au meilleur niveau est définie par

$$v^1(t) = \frac{TD^1_{\text{bid}}(t) - TD^1_{\text{ask}}(t)}{TD^1_{\text{bid}}(t) + TD^1_{\text{ask}}(t)}.$$

Elle mesure la pression acheteuse ou vendeuse instantanée. Dans le modèle de Poisson, l'imbalance **oscille rapidement entre -1 et +1**, sans structure temporelle. Cela reflète l'absence totale de mémoire dans le processus : une forte imbalance à l'instant t ne prédit rien sur l'instant suivant.

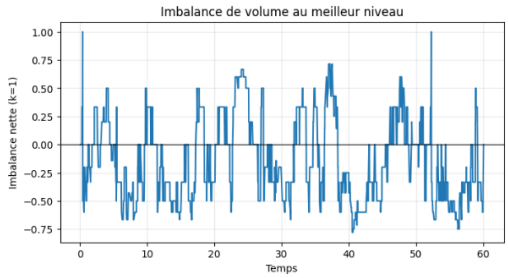

Figure 4: Imbalance au meilleur niveau

1.7.5 Cross-correlation du mid-price : mise en évidence de l'absence de clustering

Nous étudions la corrélation du mid-price avec un lag h :

$$\rho(h) = \text{Corr}(P_t,\ P_{t+h}).$$

Dans les données réelles, cette corrélation décroit lentement en raison du **clustering de volatilité** : le marché garde une mémoire de ses mouvements récents. Ici, au contraire:

- la corrélation décroît de façon **monotone et régulière**,
- elle reste toujours **positive**, signe d'une dynamique quasi-diffusive,
- elle ne montre **aucune alternance positive/négative** typique des marchés auto-excitants.

Le modèle Poisson est donc incapable de reproduire les effets de clustering observés empiriquement.

1.7.6 Convergence de la volatilité asymptotique : comparaison avec la théorie

Nous avons établit que le prix rescalé

$$\hat{P}^{(n)}(t) = \frac{P(nt) - Q(nt)}{\sqrt{n}}$$

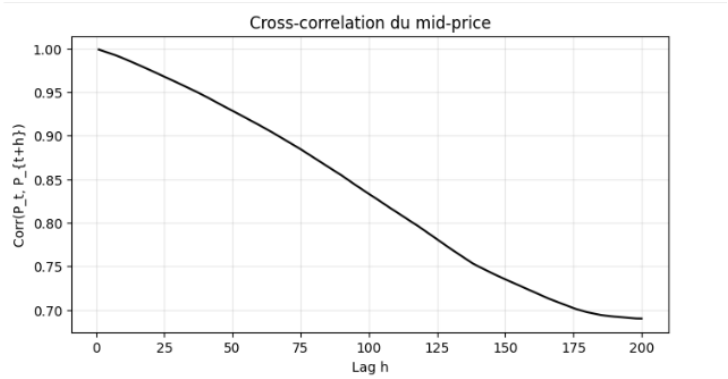

Figure 5: Cross-correlation du mid-price (modèle Poisson)

converge vers un mouvement brownien, avec une volatilité asymptotique donnée par

$$\hat{\sigma}^2 = \sum_i \int v^i(x) \left(F_i(x)\right)^2 \Pi(dx).$$

Dans nos simulations Monte-Carlo, l'estimation empirique de $\hat{\sigma}^2$:

- oscille fortement d'une trajectoire à l'autre (variance de Monte-Carlo élevée),
- reste cependant centrée autour d'une valeur stable (pointillé rouge),
- ce qui est cohérent avec la **convergence en moyenne** annoncée par le théorème limite.

L'écart entre trajectoires reflète uniquement la faible taille de l'échantillon et la nature bruitée du mid-price sous Poisson.

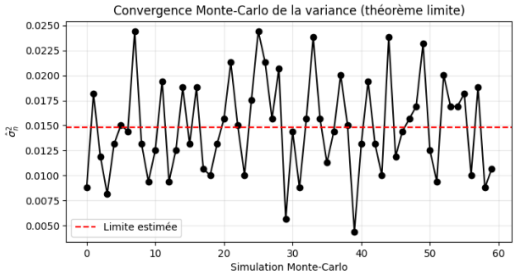

Figure 6: Convergence Monte-Carlo de la volatilité asymptotique

1.7.7 Tests d'ajustement Poisson : Q-Q plot et indépendance

Dans un processus de Poisson, les temps inter-évènements rescalés doivent suivre une loi Exp(1) et être indépendants. Le test Q-Q confirme en pratique la bonne adéquation l'Exp(1), avec un alignement quasi-parfait sur la droite $y = x$. C'est le cas pour notre simulation puisqu'on a simule des poisson.

La visualisation du nuage (U_k, U_{k+1}) montre aussi en pratique une dispersion uniforme sans structure : aucune autocorrélation, conformément au modèle théorique. (c'est à titre indicatif dans le cas d'un test sur des données réelles car nous avons bien simulé des poissons)

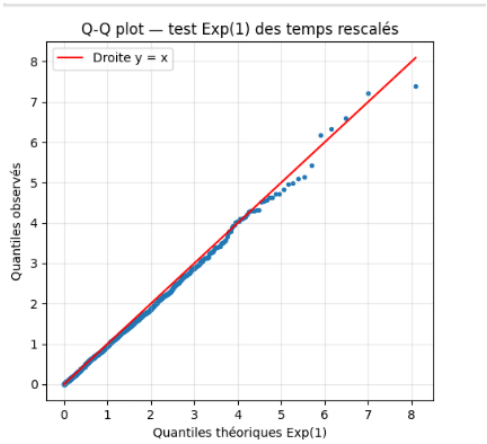

Figure 7: Q-Q plot des temps rescalés (test Exp(1))

Figure 8: Test d'indépendance : scatter plot des uniforms rescalés

2 Carnet d'ordre avec processus de Hawkes

Les modèles *zero intelligence* constituent un premier niveau de modélisation du flux d'ordres dans un carnet. Ils reposent sur l'hypothèse que les arrivées d'ordres suivent des processus de Poisson indépendants, avec des intensités fixées a priori. Ces modèles ont l'avantage de fournir un cadre extrêmement simple et tractable, permettant de dériver analytiquement des propriétés du carnet, mais ils souffrent d'une limite fondamentale : ils supposent que les ordres sont générés indépendamment les uns des autres. Or, comme le montrent de nombreuses études empiriques, les flux d'ordres observés en haute fréquence présentent une forte autocorrélation, des épisodes de *clustering* d'activité, ainsi que des dépendances croisées entre différents types d'ordres.

C'est précisément pour capturer ces phénomènes qu'interviennent les *processus de Hawkes*, introduits initialement par Hawkes (1971) et désormais largement utilisés en microstructure. Les processus de Hawkes permettent de modéliser des intensités endogènes, c'est-à-dire une dynamique où chaque événement peut augmenter temporairement le taux d'arrivée des événements futurs. Ils constituent ainsi une extension naturelle du modèle de Poisson : lorsque le noyau d'excitation est nul, on retrouve le processus de Poisson ; lorsque le noyau est positif, le processus devient auto-excité et est capable de reproduire des phénomènes de clustering très proches de ceux observés sur les marchés.

Dans ce qui suit, nous présentons d'abord la définition générale du processus de Hawkes multivarié, qui permet de modéliser plusieurs flux d'ordres en interaction. Nous introduisons ensuite une définition élargie, dite *bi-dépendante*, qui permet également de

réintégrer dans l'intensité des interactions de second ordre.

Définition 1 — Processus de Hawkes multivarié. Soit $n \in \mathbb{N}^*$. On considère un processus ponctuel multivarié

$$(N^i)_{i=1,\dots,n}.$$

On dit que (N^i) est un *processus de Hawkes multivarié* s'il existe :

- des fonctions d'interaction $(h_{ij})_{1\leq i,j\leq n}$,
- et des intensités spontanées $(\mu_i)_{1\leq i\leq n}$ avec $\mu_i > 0$,

tels que l'intensité conditionnelle du processus N^i est donnée par

$$\lambda_i(t) = \mu_i + \sum_{j=1}^{n} \int_0^t h_{ij}(t-s)\,\mathrm{d}N^j(s).$$

Cette écriture montre clairement que chaque événement survenu sur le processus N^j peut influencer l'intensité future du processus N^i, permettant de capturer à la fois l'auto-excitation (cas $i = j$) et l'excitation croisée ($i \neq j$).

Définition 2 — Processus de Hawkes bi-dépendant. On considère à nouveau un processus ponctuel multivarié $(N^i)_{i=1,\dots,n}$. On dit qu'il s'agit d'un *processus de Hawkes bi-dépendant* s'il existe :

- des fonctions d'interaction $(h_{ij})_{1\leq i,j\leq n}$,
- des fonctions de bi-interaction $(g_{i,j\to k})_{i,j,k=1,\dots,n}$,
- et des intensités spontanées (μ_i) positives,

tels que l'intensité conditionnelle du processus N^k est donnée par

$$\lambda_k(t) = \mu_k + \sum_{j=1}^{n} \int_0^t h_{kj}(t-s)\,\mathrm{d}N^j(s) + \sum_{i,j=1}^{n} \int_0^t g_{i,j\to k}(t-s, t-u)\,\mathrm{d}N^i(s)\,\mathrm{d}N^j(u).$$

La première somme correspond aux interactions classiques des processus de Hawkes linéaires, tandis que la seconde permet de modéliser des dépendances d'ordre supérieur, où l'occurrence simultanée ou rapprochée de deux événements peut influencer l'intensité d'un troisième processus. Ces modèles, bien que plus complexes, permettent de capturer des interactions structurelles fines dans les carnets d'ordres.

2.1 Noyaux exponentiels et condition de stabilité

Dans la suite, nous nous restreignons au cas linéaire avec noyaux exponentiels, qui présente deux avantages essentiels pour la modélisation du carnet d'ordres :

- il admet une représentation markovienne de dimension finie pour les intensités ;
- il fournit une condition simple de non-explosion et d'ergodicité.

On suppose que les noyaux sont de la forme

$$h_{ij}(t) = \alpha_{ij} e^{-\beta_{ij} t}, \qquad \alpha_{ij} \geq 0,\ \beta_{ij} > 0,$$

et l'on définit la matrice de reproduction

$$A_{ij} = \int_0^{+\infty} h_{ij}(t)\,\mathrm{d}t = \frac{\alpha_{ij}}{\beta_{ij}}.$$

Proposition 2.1 (Stabilité d'un Hawkes multivarié exponentiel)**.** *Supposons que la matrice $A = (A_{ij})$ soit à coefficients non négatifs et que son rayon spectral satisfasse*

$$\rho(A) < 1.$$

Alors il existe un unique processus de Hawkes multivarié $(N^i)_{i=1,\dots,n}$ dont l'intensité est donnée par la Définition 1. De plus, ce processus admet une distribution stationnaire unique et converge vers celle-ci de façon exponentiellement rapide en norme de variation totale.

Cette condition s'interprète naturellement dans la représentation en processus de ramification : A_{ij} représente le nombre moyen d'« enfants » de type i engendrés par un événement de type j. La condition $\rho(A) < 1$ garantit que le nombre d'événements descendants reste en moyenne fini, empêchant l'explosion du processus et assurant l'existence d'un régime stationnaire pour les intensités.

2.2 Algorithme de thinning d'Ogata pour la simulation exacte

Dans la partie précédente, nous avons simulé des processus de Poisson (homogènes ou non homogènes) en exploitant la loi du minimum de variables exponentielles. Pour un processus de Hawkes, l'intensité $\lambda(t)$ est elle-même aléatoire et dépend du passé ; on ne peut donc plus générer directement les temps d'arrivée à partir d'une loi simple. L'algorithme classique d'Ogata permet néanmoins une simulation exacte en procédant par *thinning* (élagage) d'un processus de Poisson majorant.

On se place dans le cas univarié pour alléger les notations ; l'extension au cas multivarié se fait composante par composante.

Proposition 2.2 (Algorithme de thinning d'Ogata)**.** *Soit $(\lambda_t)_{t\geq 0}$ une intensité prévisible, càdlàg et bornée par une constante $\Lambda^* > 0$, c'est-à-dire $\lambda_t \leq \Lambda^*$ pour tout t. On considère le schéma suivant :*

Algorithm 1 Thinning d'Ogata pour un processus de Hawkes univarié

Initialiser le temps $t \leftarrow 0$ et le compteur d'événements $N \leftarrow 0$
Choisir une borne supérieure initiale Λ^* de l'intensité
while $t < T_{\max}$ **do**
  Générer un délai candidat $\Delta \sim \mathrm{Exp}(\Lambda^*)$
  Définir le temps proposé $s \leftarrow t + \Delta$
  if $s > T_{\max}$ **then**
    stopper l'algorithme
  end if
  Calculer l'intensité courante $\lambda(s)$
  Générer $U \sim \mathcal{U}(0,1)$
  if $U \leq \dfrac{\lambda(s)}{\Lambda^*}$ **then**
    Accepter l'événement : enregistrer $T_{N+1} \leftarrow s$
    Mettre à jour $N \leftarrow N + 1$
  end if
  Mettre à jour le temps courant $t \leftarrow s$
end while

Alors le processus de comptage

$$N(t) := \#\{k : T_k \leq t\}$$

obtenu par cet algorithme est un processus ponctuel de prédicable intensité λ_t.

Proof. On considère un processus de Poisson *marqué* $\tilde{N}$ sur $\mathbb{R}_+ \times [0,1]$ de mesure d'intensité $\Lambda^* \,\mathrm{d}t \,\mathrm{d}z$, indépendant de tout le reste. Les temps candidats s apparaissant dans l'algorithme correspondent exactement aux abscisses des points de $\tilde{N}$; les marques U sont leurs ordonnées uniformes.

On définit alors

$$N(t) = \int_{[0,t]\times[0,1]} \mathbf{1}_{\{z \leq \lambda_s/\Lambda^*\}} \, \tilde{N}(\mathrm{d}s, \mathrm{d}z).$$

Par la théorie standard des processus ponctuels (théorème de *thinning*), le compensateur de N est donné par

$$\int_0^t \lambda_s \,\mathrm{d}s,$$

ce qui signifie précisément que N a pour intensité prédicable $(\lambda_t)_{t\geq 0}$. En pratique, l'algorithme ci-dessus n'est rien d'autre que la construction explicite de ce *thinning* : chaque point de $\tilde{N}$ est accepté avec probabilité λ_s/Λ^* et rejeté sinon. Les temps acceptés forment alors un processus ponctuel de la loi voulue. □

Dans le cas d'un processus de Hawkes à noyau exponentiel

$$\lambda(t) = \mu + \sum_{T_k < t} \alpha e^{-\beta(t - T_k)},$$

il est commode de maintenir, en plus de la liste des temps (T_k), une variable d'« excitation résiduelle » $E(t)$ telle que

$$E(t) = \sum_{T_k < t} e^{-\beta(t-T_k)}.$$

Entre deux candidats t et s, cette quantité décroît de façon déterministe

$$E(s^-) = E(t)\, e^{-\beta(s-t)},$$

et lorsqu'un point est accepté à l'instant s, on met simplement

$$E(s) = E(s^-) + 1.$$

On peut alors calculer $\lambda(s) = \mu + \alpha E(s^-)$ en temps constant, ce qui rend la simulation très efficace.

2.3 Générateur infinitésimal du carnet d'ordres avec intensités de Hawkes

On revient maintenant au carnet d'ordres discret décrit dans la section précédente. Rappelons que son état à l'instant t est donné par le vecteur

$$X(t) = (X_1(t), \ldots, X_n(t)),$$

et que nous avons introduit l'ensemble des évènements élémentaires

$$\mathcal{E} = \{(\mathrm{LB}, i),\ (\mathrm{LS}, i),\ (\mathrm{CB}, i),\ (\mathrm{CA}, i) : i = 1, \ldots, n\} \ \cup\ \{\mathrm{MB},\ \mathrm{MS}\},$$

avec, pour chaque $e \in \mathcal{E}$, une application de mise à jour

$$\Psi_e : X \mapsto X^{(e)}$$

décrivant l'effet de l'évènement e sur le carnet (ajout ou suppression d'un ordre, mise à jour des meilleurs prix, etc.).

Dans le modèle zéro-intelligence, chaque évènement e arrivait avec une intensité $\lambda_e(X)$ qui ne dépendait que de l'état courant du carnet. Dans le modèle à intensités de Hawkes, nous considérons un vecteur d'intensités

$$\Lambda(t) = \big(\lambda_e(t)\big)_{e \in \mathcal{E}}$$

solution d'un système de Hawkes multivarié,

$$\lambda_e(t) = \mu_e + \sum_{e' \in \mathcal{E}} \int_0^t h_{ee'}(t-s)\, \mathrm{d}N_{e'}(s),$$

où $N_{e'}$ est le processus de comptage associé au type d'évènement e'.

Pour les noyaux exponentiels $h_{ee'}(t) = \alpha_{ee'} e^{-\beta_{ee'} t}$, il est naturel d'introduire, pour chaque couple (e, e'), une variable d'excitation

$$E_{ee'}(t) = \int_0^t e^{-\beta_{ee'}(t-s)} \, \mathrm{d}N_{e'}(s),$$

de sorte que

$$\lambda_e(t) = \mu_e + \sum_{e' \in \mathcal{E}} \alpha_{ee'} E_{ee'}(t).$$

L'état complet du système devient alors

$$Z(t) = \big(X(t),\, E_{ee'}(t)\big)_{e,e' \in \mathcal{E}}.$$

Proposition 2.3 (Générateur infinitésimal élémentaire)**.** *Soit F une fonction test suffisamment régulière (par exemple C^1 en les variables $E_{ee'}$) définie sur l'espace d'états du système $Z(t)$. Le générateur infinitésimal $\mathcal{L}^{\mathrm{H}}$ du carnet d'ordres piloté par les intensités de Hawkes est donné par*

$$(\mathcal{L}^{\mathrm{H}} F)(x, E) = \underbrace{\sum_{e \in \mathcal{E}} \lambda_e(x, E) \Big(F\big(\Psi_e(x),\, E + \Delta_e(E)\big) - F(x, E) \Big)}_{\textit{termes de saut (évènements sur le carnet)}}$$
$$+ \underbrace{\sum_{e,e' \in \mathcal{E}} \Big(-\beta_{ee'} E_{ee'} \Big) \frac{\partial F}{\partial E_{ee'}}(x, E)}_{\textit{dérive déterministe entre les sauts}},$$

où $\Delta_e(E)$ encode les sauts des variables d'excitation lorsque l'évènement e se produit :

$$\big[\Delta_e(E)\big]_{k\ell} = \begin{cases} 1, & \textit{si } \ell = e, \\ 0, & \textit{sinon.} \end{cases}$$

Le premier terme de $(\mathcal{L}^{\mathrm{H}} F)$ généralise le générateur du modèle zéro-intelligence : à chaque type d'évènement e, pondéré par son intensité courante $\lambda_e(x, E)$, on applique la transformation Ψ_e au carnet et on ajoute les sauts appropriés aux excitations E_{ke}. Le second terme décrit la décroissance exponentielle continue des excitations entre les sauts, propre au noyau exponentiel.

Ce générateur fournit une base rigoureuse pour :

- l'étude théorique du comportement de long terme du carnet (ergodicité, stabilité), via des fonctions de Lyapunov adaptées ;
- la formulation de problèmes de contrôle stochastique ou d'apprentissage par renforcement, en écrivant l'équation de Hamilton–Jacobi–Bellman associée sur l'espace d'états étendu (X, E).

Théorème 2.4 (Théorème central-limite du prix sous Hawkes)**.** *Considérons le processus de prix*

$$P_t = \sum_i \int_0^t F_i\big(X(s)\big)\, dN^i(s),$$

où $(N^i)_i$ *sont des processus de Hawkes multivariés stationnaires,* $X(t)$ *le carnet d'ordres, et* $F_i(X)$ *le saut de prix provoqué par un événement de type* i*.*

Notons

$$Q_t = \sum_i \int_0^t \nu^i\big(X(s)\big)\, F_i\big(X(s)\big)\, ds$$

le compensateur prévisible du prix. Alors le processus centré et renormalisé

$$P^{(n)}(t) = \frac{P_{nt} - Q_{nt}}{\sqrt{n}}$$

converge en loi, lorsque $n \to \infty$*, vers un mouvement brownien* $\widehat{\sigma} W_t$*, où la volatilité asymptotique est donnée par*

$$\widehat{\sigma}^2 = \sum_i \int \nu^i(x)\, \big(F_i(x) - \Delta_i^*(x)\big)^2\, \Pi(dx).$$

Proof. La preuve repose sur deux ingrédients classiques : (1) la convergence presque sûre de la variation quadratique prévisible, assurée par l'ergodicité du couple $(X(t), N(t))$; (2) le théorème central-limite pour martingales, appliqué au prix centré. Les conditions d'intégrabilité sont satisfaites grâce à la décroissance exponentielle des noyaux de Hawkes, ce qui garantit la majoration uniforme des intensités et donc la borne des sauts du martingale. □

2.4 Analyse des features du carnet d'ordres sous modèles de Hawkes

Le modèle de Poisson fournit une base de comparaison utile mais reste incapable de reproduire deux caractéristiques essentielles des carnets d'ordres réels : (i) le *clustering* des arrivées d'ordres (périodes d'activité intense alternant avec des phases calmes) et (ii) la dépendance entre les flux d'ordres agressifs (ordres de marché) et la réponse des fournisseurs de liquidité (ordres limites). Les processus de Hawkes permettent précisément de modéliser ces effets d'auto-excitation et d'excitation croisée : un ordre augmente temporairement la probabilité d'observer de nouveaux ordres, soit du même type, soit d'un autre type.

Nous considérons deux variantes :

- un **modèle Hawkes simple** où les ordres de marché (MO) sont auto-excités et les ordres limites (LO) sont à la fois auto-excités et excités par les MO (terme MO → LO), les annulations (CXL) restant de type Poisson indépendant.

Paramètres du modèle Hawkes simple	**Valeur**
Processus MO (Market Orders)	
Intensité de base μ_{MO}	0.50
Auto-excitation $(\alpha_{\text{MO}}, \beta_{\text{MO}})$	(0.70, 1.20)
Cross-excitation	aucune
Processus LO (Limit Orders)	
Intensité de base μ_{LO}	0.60
Auto-excitation $(\alpha_{\text{self}}, \beta_{\text{self}})$	(0.40, 1.20)
Excitation MO $\rightarrow$ LO $(\alpha_{\text{cross}}, \beta_{\text{cross}})$	(0.80, 1.00)
Intensité de base μ_{CXL}	0.50
Excitation additionnelle	aucune (Poisson indépendant)

Table 2: Paramètres du modèle Hawkes simple utilisé pour la simulation du carnet d'ordres (auto-excitation MO/LO et cross-excitation MO→LO).

- un **modèle Hawkes bi-interaction**, où l'on ajoute un noyau de bi-interaction pour capter l'effet de couples d'événements rapprochés (par exemple deux MO successifs ou un couple MO–LO). Le terme LO $\rightarrow$ MO est fixé à zéro : économiquement, on suppose que ce sont surtout les agressions de marché qui déclenchent une réponse des fournisseurs de liquidité (MO $\rightarrow$ LO), alors que l'apparition de nouvelles quotes passives n'incite pas immédiatement les traders à envoyer davantage d'ordres de marché.

Paramètres du modèle Hawkes bi-interaction	**Valeur**
Fenêtre d'interaction (pair_window)	1.0
Processus MO	
Intensité de base μ_{MO}	0.25
Auto-excitation $(\alpha_{\text{self}}, \beta_{\text{self}})$	(0.40, 1.80)
Cross-excitation $(\alpha_{\text{cross}}, \beta_{\text{cross}})$	(0.00, 1.00)
Bi-interaction $(\eta_{\text{bi}}, \delta_{\text{bi}})$	(0.20, 2.50), (MO, MO)
Processus LO	
Intensité de base μ_{LO}	0.50
Auto-excitation $(\alpha_{\text{self}}, \beta_{\text{self}})$	(0.30, 1.50)
Cross-excitation MO $\rightarrow$ LO $(\alpha_{\text{cross}}, \beta_{\text{cross}})$	(0.60, 1.50)
Bi-interaction $(\eta_{\text{bi}}, \delta_{\text{bi}})$	(0.15, 2.50) , (MO, LO)
Intensité de base μ_{CXL}	0.40

Table 3: Hyperparamètres du modèle Hawkes bi-interaction utilisé pour la simulation du carnet d'ordres.

L'objectif est de comparer, pour ces deux modèles, l'impact sur les principales features du carnet : mid-price, spread, profondeur, imbalance et intensités d'ordres.

2.4.1 Mid-price : réactions en régime auto-existant

Dans les deux modèles de Hawkes, le mid-price reste globalement borné autour de son niveau initial, mais son comportement diffère de la simulation de Poisson. Le modèle Hawkes simple génère des mouvements par à-coups associés aux rafales d'ordres de marché : les variations de prix se concentrent dans des épisodes courts, séparés par des phases plus stables. Avec la bi-interaction, ces épisodes sont encore plus marqués : des séquences rapprochées de MO ou de couples MO–LO amplifient temporairement l'activité, puis l'intensité décroît de façon exponentielle, ce qui crée des blocs de trajectoire de prix.

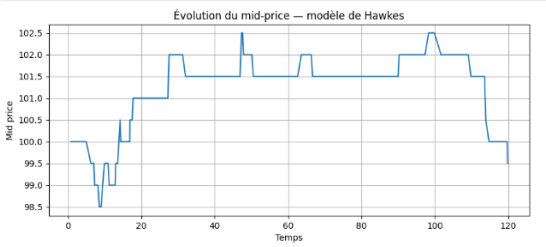

Figure 9: Mid-price — Hawkes simple (MO auto, MO→LO)

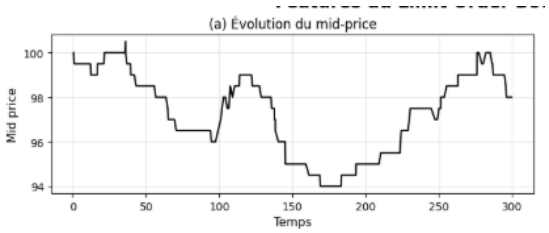

Figure 10: Mid-price — Hawkes bi-interaction

2.4.2 Spread et micro-liquidité

Sous Hawkes, le spread reste le plus souvent à son niveau minimal (deux ticks), mais l'auto-excitation des MO et des LO induit des épisodes d'élargissement plus rares et plus persistants que dans le modèle de Poisson. Dans le modèle simple, ces élargissements surviennent principalement après des salves d'ordres de marché qui vident plusieurs niveaux du carnet avant que de nouveaux ordres limites ne reconstituent la liquidité. La bi-interaction renforce ce mécanisme : des couples (MO,LO) rapprochés créent des séquences où la liquidité se retire puis revient de manière coordonnée, ce qui accentue le caractère intermittent de la micro-liquidité.

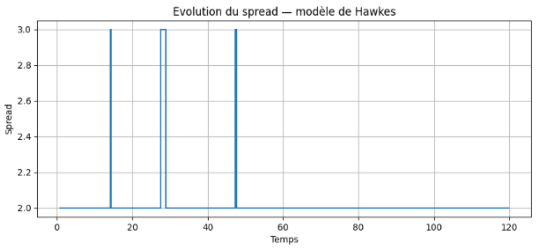

Figure 11: Spread bid–ask — Hawkes simple

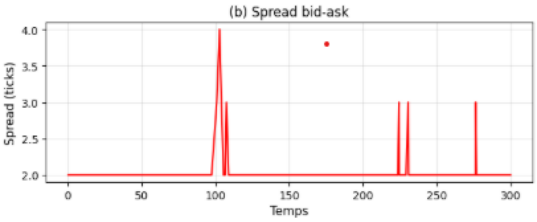

Figure 12: Spread bid–ask — Hawkes bi-interaction

2.4.3 Profondeur et déséquilibre de volume

La profondeur totale au meilleur niveau et sur l'ensemble des niveaux présente, dans les deux modèles de Hawkes, des phases de construction et de déconstruction de la liquidité. Dans le modèle simple, la profondeur bid/ask suit surtout les cycles d'auto-excitation des LO : après une agression du carnet par les MO, l'intensité des LO augmente et la profondeur se reconstitue rapidement. Dans le modèle bi-interaction, les noyaux de pair-interaction introduisent une structure plus riche : des séquences rapprochées de MO–MO ou MO–LO peuvent déclencher des vagues de fourniture ou de retrait de liquidité sur plusieurs niveaux, ce qui se traduit par des plateaux de profondeur suivis de décroissances rapides.

L'imbalance bid/ask reflète directement ces mécanismes. Dans le modèle simple, elle oscille mais reste relativement centrée, la réponse des LO amortissant rapidement les chocs de MO. Avec la bi-interaction, l'imbalance connaît des épisodes prolongés de déséquilibre (proche de 0 ou 1) correspondant à des périodes de domination d'un côté du carnet, phénomène typique des marchés réels en présence de flux d'ordres auto-corrélés.

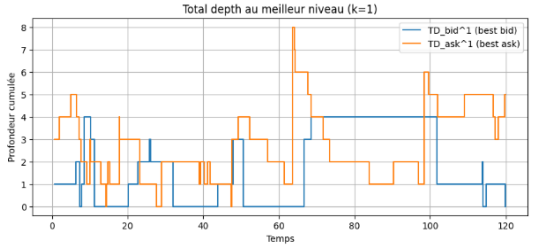

Figure 13: Profondeur au meilleur niveau — Hawkes simple

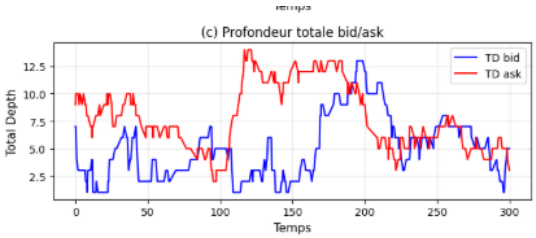

Figure 14: Profondeur et profondeur totale — Hawkes bi-interaction

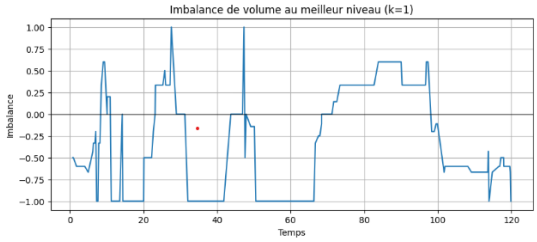

Figure 15: Imbalance niveau 1 — Hawkes simple

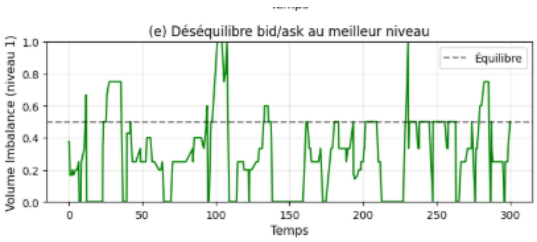

Figure 16: Imbalance multi-niveaux — Hawkes bi-interaction

2.4.4 Intensités Hawkes et phénomène de clustering

Les intensités estimées des processus Hawkes mettent en évidence le cœur du mécanisme de clustering. Dans le modèle simple, $\lambda_{\mathrm{MO}}(t)$ et $\lambda_{\mathrm{LO}}(t)$ présentent des pics localisés autour des arrivées d'événements : chaque ordre augmente temporairement la probabilité de nouveaux ordres, puis l'intensité revient progressivement vers son niveau de base. Dans le modèle bi-interaction, les contributions de bi-interaction créent des pics plus hauts et

plus larges, parfois décalés, traduisant l'influence des couples d'événements rapprochés et la propagation du choc sur plusieurs horizons temporels.

Ces pics d'intensité se retrouvent visuellement sur la timeline des événements : les barres verticales correspondant aux MO, LO et CXL se regroupent en paquets denses séparés par des zones plus calmes, ce qui contraste fortement avec la dispersion uniforme observée sous le modèle de Poisson. C'est précisément ce comportement en *grappes* que les modèles de Hawkes parviennent à reproduire et qui est essentiel pour capturer la dynamique réaliste de la liquidité intra-journalière.

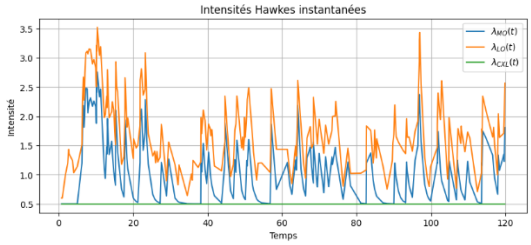

Figure 17: Intensités λ_{MO} et λ_{LO} — Hawkes simple

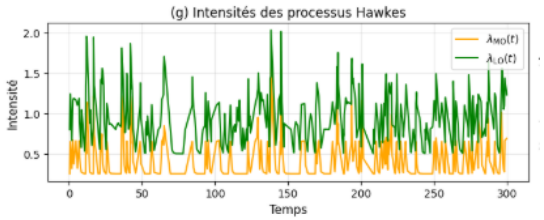

Figure 18: Intensités Hawkes et événements cumulés — bi-interaction

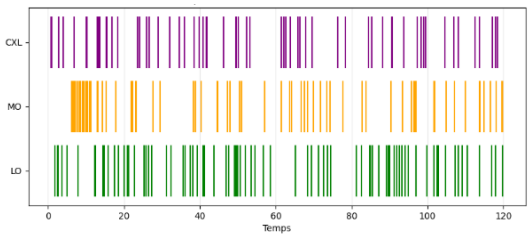

Figure 19: Timeline des événements (MO, LO, CXL) — Hawkes simple

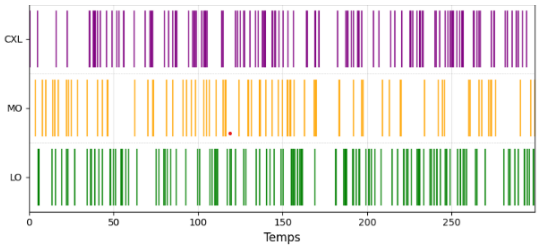

Figure 20: Timeline des événements — Hawkes bi-interaction

2.4.5 Cross-correlation du mid-price et mémoire du marché

La fonction de corrélation croisée fournit un indicateur direct de la *mémoire* induite par la dynamique des arrivées d'ordres.

Dans le modèle de Hawkes simple, la corrélation décroît lentement puis devient négative, ce qui traduit la présence d'un mécanisme d'excitation suivi d'un effet de rappel : après une rafale d'ordres, l'intensité retombe progressivement, générant des mouvements compensatoires du prix. Ce comportement est caractéristique des marchés où les flux d'ordres sont auto-corrélés.

Dans le modèle bi-interaction, la structure est encore plus marquée : la corrélation présente un minimum plus prononcé et un retour positif à horizon plus long, signature de la *mémoire de second ordre* créée par les événements couplés (MO–MO, MO–LO). Ces oscillations reflètent la propagation des chocs à travers plusieurs couches de la liquidité et rendent compte d'une dynamique plus réaliste que celle du modèle Hawkes simple.

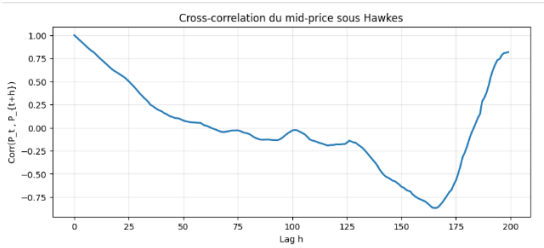

Figure 21: Cross-corrélation du mid-price — Hawkes simple

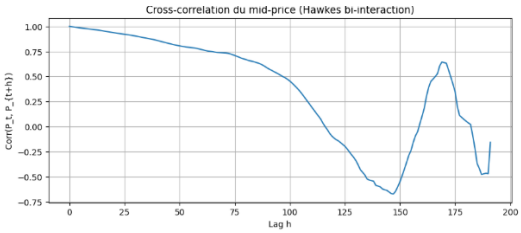

Figure 22: Cross-corrélation du mid-price — Hawkes bi-interaction

2.4.6 Volatilité asymptotique du prix et théorème limite

Le théorème limite présenté dans la section précédente établit que le mid-price centré et renormalisé converge vers un mouvement brownien dont nous avons caractérisé la variance .

Sous Hawkes simple, l'estimation Monte-Carlo de $\widehat{\sigma}^2$ présente une forte variabilité : les pics d'auto-excitation des ordres de marché provoquent des épisodes d'activité concentrée, suivis de périodes plus calmes, ce qui rend l'évaluation de la variance plus instable. Cette dispersion reflète fidèlement la nature explosive puis décroissante du noyau de Hawkes.

Dans le modèle bi-interaction, la convergence est nettement plus stable : les interactions de second ordre adoucissent les contrastes d'intensité et produisent un régime stationnaire plus proche des hypothèses du théorème limite. L'estimation de la variance asymptotique est ainsi presque constante d'une simulation à l'autre, illustrant que la dynamique bi-interaction génère un processus plus ergodique et mieux régularisé.

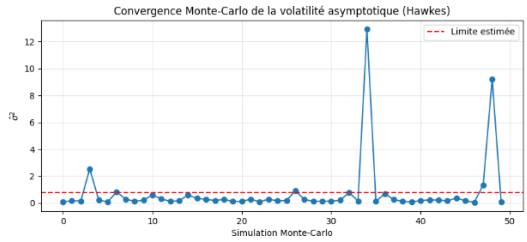

Figure 23: Volatilité asymptotique estimée — Hawkes simple

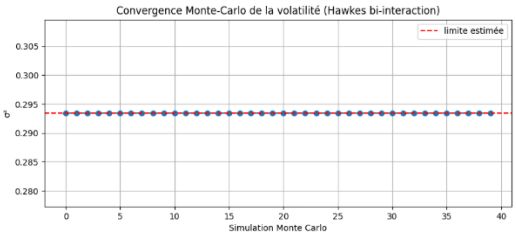

Figure 24: Volatilité asymptotique estimée — Hawkes bi-interaction

3 Problème d'exécution optimale

L'exécution optimale vise à déterminer la manière la plus efficiente de liquider une position importante tout en minimisant les coûts induits par l'impact de marché. Lorsque l'agent cherche à écouler une quantité initiale $X_0 > 0$ de titres sur un horizon fini $[0, T]$, exécuter l'intégralité de la position dès l'instant initial génère en général un impact significatif, et il est donc préférable de répartir progressivement les transactions dans le temps. Pour formaliser cette idée, nous supposons que l'horizon $[0, T]$ est discrétisé en $N + 1$ instants

réguliers

$$t_k = \frac{kT}{N}, \qquad k = 0, \dots, N,$$

et que l'agent choisit à chaque date t_k une quantité $x_k \geq 0$ à exécuter. Une stratégie d'exécution admissible est donc une suite $(x_0, \dots, x_N)$ vérifiant la contrainte de liquidation

$$\sum_{k=0}^{N} x_k = X_0,$$

qui garantit que l'intégralité de la position a été écoulée avant l'horizon terminal.

À chaque date t_k, la transaction de taille x_k est exécutée au prix effectif P_k (prix unitaire) , potentiellement différent d'un prix de référence $P_{0,k}$ mesurant la valeur du titre en l'absence d'impact. La perte imputable à l'impact de marché, ou *implementation shortfall*, est alors quantifiée par le coût marginal

$$C_k = (P_{0,k} - P_k)x_k.$$

Le coût total associé à une stratégie $x = (x_0, \dots, x_N)$ s'écrit donc

$$C(x) = \sum_{k=0}^{N} (P_{0,k} - P_k)x_k.$$

L'objectif de l'agent est de choisir une trajectoire d'exécution minimisant l'espérance de ce coût total, sous la contrainte de liquidation. Le problème d'exécution optimale prend ainsi la forme

$$\min_{x \in \mathcal{A}} \mathbb{E}\left[\sum_{k=0}^{N} (P_{0,k} - P_k)x_k\right], \tag{2}$$

où l'ensemble admissible est défini par

$$\mathcal{A} = \left\{(x_0, \dots, x_N) \in \mathbb{R}_+^{N+1} : \sum_{k=0}^{N} x_k = X_0\right\}. \tag{3}$$

Ce formalisme met directement l'accent sur la minimisation de l'*implementation shortfall*, en capturant les dégradations de prix générées par l'action du trader. Il constitue un cadre flexible permettant d'intégrer diverses modélisations de la dynamique des prix ou du carnet d'ordres : modèles sans mémoire (processus de Poisson), modèles auto-excitants (processus de Hawkes), ou modèles d'impact structurel tels qu'Almgren–Chriss. La nature du processus $(P_{0,k}, P_k)$ conditionne alors la structure des stratégies optimales et détermine la manière dont les ordres doivent être répartis dans le temps.

3.1 État de l'art

L'exécution optimale s'est imposée comme un problème central en microstructure financière, et les premières contributions majeures remontent au travail de Bertsimas et

Lo, qui proposent en 1998 un cadre stochastique reposant sur la programmation dynamique pour déterminer la stratégie minimisant le coût moyen d'un programme d'achat ou de vente [1]. Leur modèle, construit sur une représentation en temps discret et des hypothèses de prix exogènes, ouvre la voie à l'étude mathématique de l'impact de marché. Une avancée décisive survient ensuite avec le modèle d'Almgren et Chriss, qui introduisent explicitement l'impact temporaire et permanent des ordres, ainsi qu'un compromis entre risque et impact [2] ; ce modèle devient rapidement le standard de référence dans la littérature comme dans l'industrie. Les travaux d'Huberman et Stanzl prolongent cette approche en caractérisant les formes d'impact compatibles avec l'absence d'arbitrage [3], tandis que l'ouvrage de Guéant systématise et étend ces modèles en intégrant des dynamiques plus générales et des structures d'impact non linéaires [4].

Si ces approches structurelles permettent d'obtenir des solutions analytiques ou quasi analytiques, elles reposent toutefois sur une description simplifiée du carnet d'ordres et ne capturent ni les dépendances à haute fréquence ni l'auto-excitation typique des flux d'ordres. Pour pallier ces limites, Nevmyvaka et al. introduisent en 2006 l'apprentissage par renforcement dans ce contexte, en montrant qu'un agent entraîné par Q-learning peut surpasser des stratégies déterministes classiques [5]. Cependant, la malédiction de la dimensionnalité rend rapidement le Q-learning tabulaire impraticable pour des états riches dérivés du carnet d'ordres. Cette observation motive l'émergence de méthodes hybrides, telles que celle d'Hendricks et Wilcox, qui combinent le modèle d'Almgren–Chriss avec un ajustement dynamique via Q-learning [6]. Les progrès rapides de l'apprentissage profond permettent ensuite l'apparition d'architectures plus puissantes, notamment le Deep Q-Network (DQN) de Mnih et al., utilisé par Lin et Beling pour traiter des représentations d'état de grande dimension issues du carnet d'ordres [7, 8]. En parallèle, des méthodes d'apprentissage par politique comme PPO, introduites par Schulman et al., sont également appliquées au problème d'exécution afin de capturer des dépendances temporelles plus fines [9].

Plus récemment, le besoin de simuler un environnement de marché réaliste conduit à la création d'ABIDES, un cadre multi-agents développé par Byrd et Karp permettant de reproduire finement la dynamique d'un carnet d'ordres [10, 11]. Ce simulateur rend possibles des approches d'apprentissage interactif : Karp et al. utilisent notamment DDQL pour apprendre des stratégies d'exécution dans un marché simulé peuplé d'agents hétérogènes [12]. D'autres travaux, tels que ceux de Nagy et al., explorent l'intégration de signaux prédictifs dans les méthodes de Q-learning profond, ouvrant la voie à des stratégies exploitant à la fois l'impact de marché et des anticipations directionnelles [13]. Dans la continuité de ces contributions, notre étude s'inscrit dans l'objectif de mettre en œuvre un algorithme DQN pour l'exécution optimale d'ordres dans un environnement de carnet d'ordres réaliste.

3.2 Processus de décision markovien (MDP)

Pour formaliser l'interaction entre un agent et un environnement dynamique, nous adoptons le cadre des processus de décision markoviens (MDP) au sens de Puterman [15]. L'espace d'états est un ensemble dénombrable X, et à chaque état $x \in X$ correspond un

ensemble fini d'actions admissibles $A(x)$. Lorsqu'une action $a \in A(x)$ est choisie au temps (étape) k, le système évolue selon une transition probabiliste

$$P_{xy}^a = \mathbb{P}(X_{k+1} = y \mid X_k = x, a_k = a),$$

et l'agent reçoit un gain immédiat G_{xy}^a, supposé borné.

Une politique stationnaire est une application $\sigma : X \to A(\cdot)$ définissant l'action à exécuter dans chaque état. Plus généralement, une politique non-stationnaire est une suite $(\pi_0, \pi_1, \dots)$, où π_k indique l'action à appliquer au temps k. Sous une telle politique, la dynamique du système est régie par une chaîne de Markov non stationnaire vérifiant

$$\mathbb{P}_\pi(X_{k+1} = y \mid X_k = x) = P_{xy}^{\pi_k(x)}.$$

3.2.1 Fonction valeur en horizon fini

Pour un horizon N et un état initial x_0, la performance d'une politique π est mesurée par la somme des gains cumulés jusqu'à l'horizon,

$$v_{x_0}^N(\pi) = \mathbb{E}_\pi\left[G_{X_0X_1} + \cdots + G_{X_{N-1}X_N} + b_{X_N} \;\middle|\; X_0 = x_0\right],$$

où b est un gain terminal. La fonction valeur optimale est définie par

$$v_{x_0}^N := \sup_\pi v_{x_0}^N(\pi).$$

3.2.2 Équation de programmation dynamique

Le résultat structurant est le théorème de Bellman, qui établit la récurrence

$$v_x^n = \max_{a \in A(x)} \sum_{y \in X} P_{xy}^a \left(G_{xy}^a + v_y^{n-1}\right), \qquad v_x^0 = b_x.$$

Cette relation définit l'opérateur de Bellman

$$[B(v)]_x = \max_{a \in A(x)} \sum_y P_{xy}^a (G_{xy}^a + v_y), \qquad v^n = B(v^{n-1}),$$

dont l'itération rétrograde fournit la valeur optimale à horizon fini.

L'essence de la démonstration repose sur la propriété de Markov : dans le cas non contrôlé, on obtient immédiatement

$$v_x^n = \sum_y P_{xy}(G_{xy} + v_y^{n-1}).$$

Dans le cas contrôlé, un lemme de sélection assure qu'il existe toujours une action atteignant le maximum dans $B(v)$, ce qui permet de construire des politiques optimales par récurrence. En itérant ces choix à chaque étape, on obtient que les politiques ainsi construites atteignent l'égalité dans la borne supérieure, ce qui établit formellement la récurrence de Bellman. □

3.3 Apprentissage par renforcement

Le cadre des MDP constitue la base théorique de l'apprentissage par renforcement (RL), dans lequel un agent cherche à apprendre, par interaction avec l'environnement, une politique maximisant une récompense cumulée. Un MDP discret est décrit par le quintuplet

$$(X, A(\cdot), P, G, \gamma),$$

où X est l'espace d'états, $A(x)$ l'ensemble des actions disponibles en x, P^a_{xy} les probabilités de transition, G^a_{xy} les récompenses immédiates, et $\gamma \in (0, 1]$ un facteur d'actualisation qui pondère les gains futurs.

Une politique stochastique est décrite par une distribution $\pi(a \mid x)$ sur les actions admissibles. Pour un horizon fini T, une trajectoire générée par l'agent est de la forme

$$(x_0, a_0, r_1, x_1, a_1, r_2, \ldots, x_{T-1}, a_{T-1}, r_T),$$

où chaque récompense découle des dynamiques du MDP :

$$r_{k+1} = G^{a_k}_{x_k x_{k+1}}.$$

La performance attendue d'une politique π, à partir d'une distribution initiale μ, est alors définie par le retour escompté

$$J_\pi = \mathbb{E}_{x_0 \sim \mu,\, \pi} \left[\sum_{i=1}^{T} \gamma^{i-1} r_i \right].$$

L'objectif de l'agent est de résoudre

$$\pi^\star \in \arg\max_\pi J_\pi,$$

c'est-à-dire de déterminer une politique maximisant le gain escompté.Il est important de remarquer qu'en prenant comme fonction de récompense $r_t = -C_t$, ce problème de maximisation a pour dual le problème de minimisation du manque à gagner comme définit plus haut.

Dans ce travail, nous nous concentrons sur l'algorithme *Deep Q-Network* (DQN) de Mnih et al. [7], qui combine Q-learning et réseaux neuronaux profonds pour approximer la fonction valeur-action

$$Q^\pi(x, a) = \mathbb{E}_\pi \left[\sum_{i=1}^{T} \gamma^{i-1} r_i \mid X_0 = x, A_0 = a \right].$$

L'utilisation d'un *target network* et d'un *experience replay buffer* améliore la stabilité de l'apprentissage et permet d'aborder des espaces d'état de grande dimension, tels que ceux dérivés du carnet d'ordres. L'alogrithme de **DQN** est illustré ci dessous.

Algorithm 2 Deep Q-Network pour l'exécution optimale

Initialiser la mémoire de rejouement $\mathcal{D}$ avec une capacité N
Initialiser le réseau d'approximation $Q_\theta(x, a)$ avec des poids aléatoires
for épisode = 1 **to** M **do**
  Initialiser l'état X_1 (position initiale et état du marché)
  for $t = 1$ **to** T **do**
    Avec probabilité ε, choisir une action aléatoire $A_t \in A(X_t)$
    Sinon choisir

$$A_t \in \arg\max_{a \in A(X_t)} Q_\theta(X_t, a)$$

    Exécuter l'action A_t (transaction de quantité correspondante)
    Observer la récompense $r_t = -C_t$ et le nouvel état X_{t+1}
    Stocker la transition (X_t, A_t, r_t, X_{t+1}) dans $\mathcal{D}$
    Prélever un minibatch de transitions (X_j, A_j, r_j, X_{j+1}) depuis $\mathcal{D}$
    Calculer la cible de Bellman :

$$y_j = r_j + \gamma \max_{a'} Q_\theta(X_{j+1}, a')$$

    Mettre à jour les paramètres θ par descente de gradient sur :

$$(y_j - Q_\theta(X_j, A_j))^2$$

  end for
end for

3.4 Stratégie d'exécution par apprentissage par renforcement

L'objectif est de construire une politique d'exécution capable de déterminer, à chaque instant de décision, la quantité optimale à vendre dans un carnet d'ordres simulé par un modèle de Hawkes. L'agent observe un état compact de dimension 4 :

$$s_t = \left(\frac{t}{T},\ \frac{X_t}{X_0},\ \mathrm{Spread}_t,\ \frac{P_{\mathrm{mid}}(t) - P_0}{P_0} \right),$$

où X_t désigne l'inventaire restant, et P_0 le mid-price initial.

L'espace d'actions est discret :

$$a \in \{0, 1, 2, 3\}, \qquad a > 0 \Rightarrow \text{exécuter } a \times q_{\min},$$

où $q_{\min} = \max\big(\lfloor X_0/N_{\mathrm{dec}} \rfloor,\ 1\big)$. Ainsi, l'agent peut rester inactif ($a = 0$) ou exécuter une quantité croissante, censurée automatiquement par l'inventaire résiduel.

La fonction $Q(s, a)$ est approximée par un réseau neuronal entièrement connecté (deux couches cachées de 64 neurones, activation ReLU), entraîné via un schéma *Deep Q-Network* : mémoire de rejouement, réseau cible mis à jour en douceur, et stratégie ε-

gloutonne pour l'exploration. Le signal de récompense encode les objectifs suivis par l'agent.

Coût d'exécution. Lorsque l'agent vend une quantité q à un prix moyen P_{exec}, le coût unitaire de l'opération est l'*implementation shortfall*

$$\text{cost}_t = (P_0 - P_{\text{exec}})\, q,$$

qui est positif si l'agent vend en dessous de la référence P_0. La contribution au reward est

$$r_t^{\text{exec}} = -\frac{\text{cost}_t}{X_0},$$

de sorte que des exécutions défavorables dégradent immédiatement le retour.

Pénalité temporelle. Pour éviter qu'un inventaire important subsiste trop tard dans l'horizon, on ajoute

$$r_t^{\text{time}} = -\lambda_{\text{time}} \left(\frac{t}{T}\right)^2 \frac{X_t}{X_0}.$$

Cette pénalité croît avec le temps (au carré) et avec l'inventaire restant : procrastiner est fortement pénalisé.

Pénalité d'inaction. Pour décourager les longues séquences d'inaction, on mémorise le nombre de décisions consécutives sans trade, noté idle_t, et l'on ajoute

$$r_t^{\text{idle}} = -\lambda_{\text{idle}} \left(e^{\text{idle}_t} - 1\right) \frac{X_t}{X_0}.$$

Cette pénalité devient rapidement importante si l'agent reste passif tout en conservant un inventaire substantiel.

Pénalité terminale. Si l'agent n'a pas liquidé toute sa position à T, on impose une pénalité cubique :

$$r_T^{\text{final}} = -\lambda_{\text{final}} \left(\frac{X_T}{X_0}\right)^3.$$

Cela force effectivement la liquidation complète avant la fin de l'horizon.

Le reward total s'écrit donc :

$$r_t = r_t^{\text{exec}} + r_t^{\text{time}} + r_t^{\text{idle}}, \qquad \text{et } r_T \leftarrow r_T + r_T^{\text{final}} \text{ si } X_T > 0.$$

Courbes d'apprentissage. Pour chaque épisode, on enregistre le retour cumulé $\sum_t r_t$ et l'on trace son évolution au cours de l'entraînement. Afin d'étudier l'influence de l'optimiseur, trois DQN distincts sont entraînés avec des taux d'apprentissage $\alpha \in \{10^{-2}, 10^{-3}, 10^{-4}\}$. Les courbes correspondantes montrent la vitesse de convergence, la stabilité et le niveau de performance asymptotique.

Une fois le réseau entraîné, on gèle ses poids et on simule un grand nombre d'épisodes, ce qui permet de reconstituer :

- la trajectoire moyenne d'exécution $(X_0 - X_t)/X_0 = x_t/X_0$,
- la distribution des spreads rencontrés lors des trades,
- la distribution des imbalances,
- la variabilité du reward final.

3.5 Stratégies baselines et comparaison avec le RL

Afin d'évaluer la politique apprise, nous la comparons à plusieurs stratégies classiques de la littérature :

Random: À chaque décision, la quantité exécutée est tirée aléatoirement parmi $\{0, q_{\min}, 2q_{\min}, 3q_{\min}\}$. Cette stratégie naïve sert de référence minimale.

TWAP: La stratégie *Time-Weighted Average Price* répartit uniformément l'inventaire. X_0/N_{dec} est exécuté à chaque décision. La trajectoire d'exécution est linéaire en temps.

VWAP: La stratégie *Volume-Weighted Average Price* exécute une quantité proportionnelle au volume exogène (ordres de marché de bruit de fond) observé jusqu'à la décision courante. L'agent "suit" le marché.

POV: La stratégie *Participation of Volume* maintient un taux de participation fixe ρ. A chaque décision, elle exécute ρ fois le volume observé depuis la précédente décision. Elle devient plus agressive lorsque l'activité du marché augmente.

Stratégie adaptive: La quantité exécutée dépend d'un indicateur d'imbalance (par exemple sur les cinq premiers niveaux du carnet). Lorsque l'imbalance est favorable au vendeur, l'exécution est augmentée ; sinon, elle est réduite.

Chaque stratégie est simulée dans exactement le même environnement Hawkes. Pour chacune, on calcule :

- la distribution des spreads observés au moment des transactions,
- la distribution de l'imbalance,

- les trajectoires d'exécution moyennes,
- la distribution du reward (ou du coût d'exécution) final.

3.6 Configuration d'apprentissage

L'algorithme d'apprentissage par renforcement utilisé dans ce travail repose sur un réseau neuronal entièrement connecté composé de deux couches cachées de 64 neurones chacune, munies de fonctions d'activation de type ReLU. L'optimisation est effectuée à l'aide de l'algorithme Adam, avec un taux d'apprentissage fixé à $\alpha = 10^{-3}$, sauf mention contraire. L'agent est entraîné sur un nombre fixe d'épisodes (typiquement 200), chacun correspondant à un horizon complet d'exécution dans un carnet d'ordres simulé à l'aide d'un modèle de Hawkes.

L'exploration suit une politique ε-greedy décroissante : la valeur initiale $\varepsilon_0 = 1.0$ décroît progressivement vers $\varepsilon_{\min} = 0.05$ selon une loi exponentielle régie par une constante de décroissance égale à 150. Un mécanisme d'expérience rejouée (replay buffer) de taille 20 000 transitions est utilisé afin de rompre les corrélations temporelles, et des mini-lots de taille 64 sont échantillonnés pour les mises à jour du réseau. Un réseau cible, mis à jour de manière douce (soft update) avec un coefficient $\tau = 0.01$, assure la stabilité de l'apprentissage. Le facteur d'actualisation est fixé à $\gamma = 0.99$.

Le signal de récompense intègre plusieurs pénalités destinées à refléter les contraintes réalistes d'un problème d'exécution : une pénalité temporelle λ_{time}, une pénalité d'inaction λ_{idle}, et une forte pénalité terminale λ_{final} appliquée sur l'inventaire résiduel. Ces termes structurent la fonction objectif en encourageant une exécution suffisamment rapide, en évitant les phases d'inaction prolongée, et en sanctionnant fortement les situations où une partie significative de la position reste non exécutée à la fin de l'horizon.

Le tableau 4 rassemble l'ensemble des hyperparamètres du modèle et de l'environnement utilisés dans nos expériences.

Paramètres DQN	**Valeur**	**Paramètres Environnement**	**Valeur**
Nombre de couches	2 (cachées)	Horizon temporel $T_{\max}$	30
Neurones par couche	64	Nombre de décisions N	20
Activation	ReLU	Inventaire initial X_0	100
Optimiseur	Adam	Taille du tick	1.0
Taux d'apprentissage α	10^{-3}	Mid-price initial	100
Taille du batch	64	Profondeur (niveaux)	5
Taille du replay buffer	20 000	λ_{time}, λ_{idle}, λ_{final}	5.0 , 2.0, 100.0
Facteur d'actualisation γ	0.99	Soft update τ	0.01
Exploration initiale ε_0	1.0	Épisodes d'entraînement	200
Exploration finale $\varepsilon_{\min}$	0.05	Constante de décroissance	150

Table 4: Hyperparamètres utilisés pour l'entraînement du DQN.

3.7 Analyse des performances de la stratégie RL

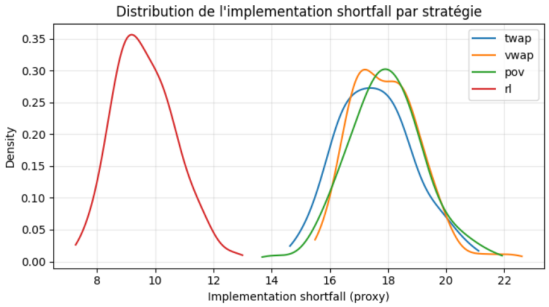

Figure 25: Distribution de l'implementation shortfall (sans *random* et *adaptive* pour améliorer la lisibilité).

Implementation shortfall. La stratégie RL présente une distribution d'implementation shortfall nettement plus favorable que les baselines TWAP, VWAP et POV, avec une moyenne située environ deux points en dessous. Cela montre que l'agent apprend effectivement à profiter des conditions de liquidité simulées dans le carnet Hawkes pour améliorer son prix d'exécution. L'absence de valeurs extrêmes dans la zone haute suggère que la pénalité finale l'incite à terminer son exécution rapidement, évitant les épisodes coûteux. Enfin, le fait de retirer *random* et *adaptive* de la figure permet de mieux visualiser les écarts entre stratégies structurées.

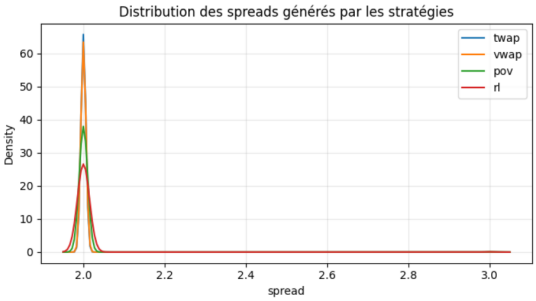

Figure 26: Distribution des spreads générés par les stratégies.

Distribution des spreads. Toutes les stratégies génèrent des spreads très concentrés autour de deux ticks, ce qui reflète la structure très stable du carnet Hawkes utilisé. La politique RL ne perturbe pas la microstructure du carnet : sa distribution de spreads est pratiquement identique à TWAP, VWAP et POV. Cela montre que l'agent n'exerce pas d'impact de marché excessif malgré son agressivité ponctuelle. Ainsi, la stratégie RL obtient un meilleur coût d'exécution sans détériorer les conditions de liquidité.

Distribution de l'imbalance. L'imbalance observée sous stratégie RL est systématiquement plus proche de zéro que celle des baselines, ce qui indique que l'agent tend à exécuter lorsque le marché est plus équilibré. Les stratégies TWAP, VWAP et POV montrent au contraire une forte concentration sur des zones d'imbalance négative, correspondant à une

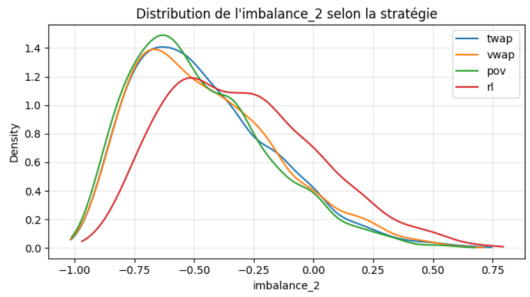

Figure 27: Distribution de l'imbalance_2 selon la stratégie.

pression vendeuse défavorable. Cette différence reflète la capacité du RL à synchroniser son exécution avec des fenêtres de liquidité plus favorables. Cela explique directement le meilleur implementation shortfall obtenu précédemment.

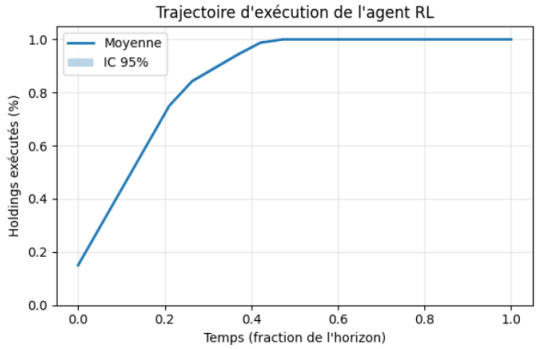

Figure 28: Trajectoire moyenne d'exécution du RL avec intervalle de confiance 95%.

Trajectoire d'exécution. Le RL adopte une trajectoire d'exécution front-loaded : environ 85% de la position est liquidée dès le premier tiers de l'horizon. Cette agressivité initiale vient de la pénalité temporelle quadratique, qui pousse l'agent à réduire rapidement son inventaire pour limiter le coût futur du temps. L'agent ralentit ensuite son exécution lorsque l'inventaire est faible, ce qui correspond à la diminution de la pénalité marginale. Globalement, la politique produite est cohérente avec la structure du reward et optimise efficacement la liquidation.

Comparaison des learning rates. Les trois learning rates mènent à une convergence similaire, ce qui montre que le problème est relativement bien conditionné pour le DQN. Le learning rate 10^{-2} apprend plus vite mais présente une variabilité supérieure, alors que 10^{-4} est plus stable mais plus lent. Le choix final 10^{-3} constitue un compromis robuste entre vitesse d'apprentissage et stabilité. Cette stabilité renforce la crédibilité des résultats obtenus en évaluation.

Courbe d'apprentissage du DQN. La courbe d'apprentissage montre une phase de forte variabilité initiale, suivie d'une convergence progressive vers un plateau autour de

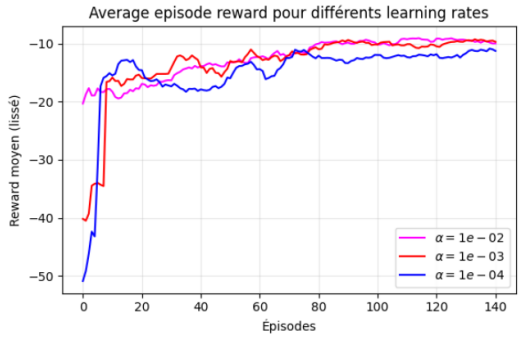

Figure 29: Comparaison des dynamiques de reward pour différents learning rates.

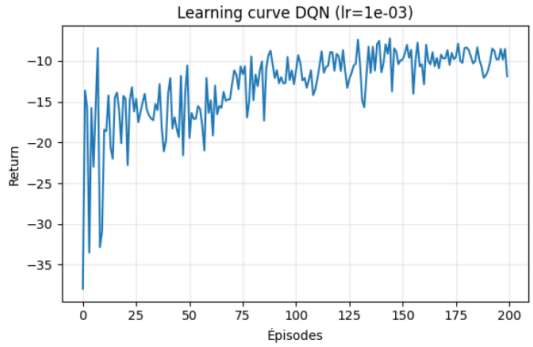

Figure 30: Courbe de reward du DQN avec le meilleur learning rate.

–10. Cette valeur correspond au minimum atteignable compte tenu des pénalités temporelles et d'inaction imposées dans le reward. Le fait que le réseau atteigne systématiquement cette zone indique qu'il apprend une politique quasi-optimale pour le design actuel de l'environnement. La stabilité finale confirme que la politique trouvée est robuste à la variance stochastique du carnet.

Conclusion

Ce travail a permis de modéliser la dynamique d'un carnet d'ordres à l'aide de processus de Poisson et de Hawkes, puis de formuler un problème d'exécution optimale dans ce cadre microstructurel. L'agent DQN construit s'est montré capable d'exploiter l'information du carnet et de battre les stratégies déterministes classiques (TWAP, VWAP, POV) en termes d'implementation shortfall et de trajectoire d'exécution. Les performances observées suggèrent que la forme du signal de récompense, notamment la combinaison des pénalités temporelles et d'inventaire final, joue un rôle central dans la qualité de la politique apprise. Dans la continuité de ce travail, une piste essentielle consiste à étudier de manière systématique l'optimalité du choix de ces pénalités, tant d'un point de vue théorique (convexité, interprétation en termes de risque) que numérique, afin d'évaluer dans quelle mesure elles influencent la stabilité de l'apprentissage et la robustesse de la stratégie obtenue.

Une seconde direction naturelle est l'exploration de méthodes de *Deep Reinforcement Learning* plus avancées, telles que PPO (Proximal Policy Optimization, une méthode de *policy gradient* réputée pour sa stabilité), SAC (Soft Actor–Critic, un algorithme *actor–critic* maximisant l'entropie pour favoriser l'exploration) ou QR-DQN (Quantile Regression DQN, une extension *distributionnelle* de DQN permettant de modéliser le risque et la variabilité des récompenses), que nous n'avons pas pu étudier faute de temps.

Enfin, une perspective particulièrement prometteuse consiste à étendre le cadre actuel à l'exécution multi-actifs ou multi-venues. Une telle extension ouvrirait la voie à des problématiques de *smart order routing*, d'arbitrage de liquidité et de gestion des corrélations de carnet, offrant ainsi un environnement beaucoup plus proche des conditions de trading institutionnel et révélateur des limites réelles des stratégies apprises.

References

[1] D. Bertsimas and A. W. Lo, "Optimal control of execution costs," *Journal of Financial Markets*, 1(1), 1998.

[2] R. Almgren and N. Chriss, "Optimal execution of portfolio transactions," *Journal of Risk*, 2001.

[3] G. Huberman and W. Stanzl, "Optimal liquidity trading," *Review of Finance*, 2005.

[4] O. Guéant, *The Financial Mathematics of Market Liquidity: From Optimal Execution to Market Making*, CRC Press, 2016.

[5] Y. Nevmyvaka, Y. Feng, and M. Kearns, "Reinforcement learning for optimized trade execution," *ICML*, 2006.

[6] D. Hendricks and D. Wilcox, "Combining Almgren–Chriss with reinforcement learning," *Working paper*, 2012.

[7] V. Mnih et al., "Human-level control through deep reinforcement learning," *Nature*, 2015.

[8] Y. Lin and P. Beling, "Deep reinforcement learning for limit order book execution," *arXiv:2002.XXX*, 2020.

[9] J. Schulman et al., "Proximal Policy Optimization Algorithms," *arXiv:1707.06347*, 2017.

[10] D. Byrd et al., "ABIDES: Agent-based interactive discrete event simulation," *arXiv:1904.12072*, 2020.

[11] D. Karp et al., "An empirical investigation of multi-agent deep RL for optimal execution," *NeurIPS Workshop*, 2020.

[12] H. van Hasselt, A. Guez, and D. Silver, "Deep Reinforcement Learning with Double Q-Learning," *AAAI*, 2016.

[13] A. Nagy et al., "Predictive signals and deep Q-learning for optimal execution," *Journal of Financial Data Science*, 2023.

[14] D. Karp et al., "Interactive learning for trade execution in multi-agent markets," *arXiv:2105.XXXXX*, 2021.

[15] Puterman, M. L. (1990). *Markov Decision Processes: Discrete Stochastic Dynamic Programming*. John Wiley & Sons.

[16] R. Cont, S. Stoikov and R. Talreja. "A Stochastic Model for Order Book Dynamics". *Operations Research*, vol. 58, no. 3, pp. 549–563, 2010.

[17] Frédéric Abergel, Marouane Anane, Anirban Chakraborti, Aymen Jedidi, Ioane Muni Toke. *Limit Order Books*. Cambridge University Press, 2016.

[18] Yadh Hafsi and Edoardo Vittori. *Optimal Execution with Reinforcement Learning*. Université Paris-Saclay & Intesa Sanpaolo, 2022.